

AWS Solutions Architect – Associate (SAA-C03): шпаргалка

Стисла версія курсу: короткі факти →  тригери «бачиш у питанні → відповідь» →  пастки. Перевірено за офіційним гайдом і документацією AWS станом на вересень 2026.

29 розділів

324 тригери

іспит: 65 питань · 130 хв · 720 / 1000

Зміст

- 1 Іспит: головні факти
- 2 Тактика: як читати питання
- 3 Основи: інфраструктура, модель відповідальності, Well-Architected
- 4 IAM і керування доступом
- 5 Шифрування, ключі, секрети, сертифікати
- 6 Сервіси безпеки: захист від атак і аудит
- 7 VPC і мережа
- 8 DNS і доставка контенту: Route 53, CloudFront, Global Accelerator
- 9 Балансувальники (ELB) і Auto Scaling
- 10 EC2: інстанси, тарифи, розміщення
- 11 Serverless і контейнери
- 12 Інтеграція і повідомлення: SQS, SNS, EventBridge, Step Functions, MQ
- 13 Amazon S3 і Glacier
- 14 Блочне і файлове сховище: EBS, Instance Store, EFS, FSx
- 15 Гібрид, міграція і перенесення даних
- 16 Бази даних: Amazon RDS
- 17 Amazon Aurora
- 18 Amazon DynamoDB
- 19 Кешування та інші бази даних
- 20 Аналітика і потоки даних

- 21 Машинне навчання, AI і фронтенд
- 22 Моніторинг, керування, інфраструктура як код
- 23 Висока доступність і Disaster Recovery
- 24 Оптимізація витрат
- 25 Цифри, ліміти і порти
- 26 «Х чи Y?» — найчастіші плутанини
- 27 Пастки, на яких найчастіше ловлять
- 28 Що змінилося у 2024–2026 (нові цифри і назви)
- 29 Як готуватися: план на 14 днів і день іспиту

Джерела

1 Іспит: головні факти

- **Код іспиту:** SAA-C03 — актуальний станом на вересень 2026. Сайти, які пишуть про «SAA-C04», помиляються: на сайті AWS такого іспиту немає.
- **Формат:** 65 питань = 50 оцінюваних + 15 неоцінюваних (які саме — невідомо, тож старайся на кожному). **130 хвилин**. Ціна **\$150**.
- **Прохідний бал:** 720 з 1000. Модель компенсаторна: не треба «здати» кожен домен окремо — рахується загальний бал.
- **Штрафу за неправильну відповідь немає** → ніколи не залишай питання порожнім.
- **Типи питань:** multiple choice (1 правильна з 4) і multiple response (2 або більше правильних з 5+; у питанні написано, скільки обрати).
- **Домени:** Design Secure Architectures — **30%**, Resilient — **26%**, High-Performing — **24%**, Cost-Optimized — **20%**.
- **+30 хвилин (ESL +30):** якщо англійська не рідна — у кабінеті aws.training/Certification → *Request Exam Accommodations* → *ESL +30 MINUTES*. Подається один раз і **до запису на іспит** (якщо вже записаний — скасуй запис, подай запит, запишись знову). Схвалюється автоматично.
- **Мови:** англійська, французька, італійська (до 31.12.2026), японська, корейська, португальська (Бразилія), іспанська, китайська. Української немає — вчи терміни англійською.
- **Назви сервісів:** в іспиті короткі назви (Amazon SNS замість Amazon Simple Notification Service). Повні назви — за кнопкою **Help** під час іспиту.
- **Де складати:** центр Pearson VUE або онлайн з проктором (вдома, з веб-камерою, чистий стіл).
- **Результат:** одразу після іспиту бала не показують — він приходить на email і в кабінет, зазвичай за кілька годин (AWS обіцяє до 5 робочих днів).
- Сертифікат діє **3 роки**. Після здачі в кабінеті є знижка 50% на наступний іспит AWS.

2 Тактика: як читати питання

- Спочатку прочитай **останнє речення** — там критерій вибору («MOST cost-effective», «LEAST operational overhead»).
- Подумки випиши всі вимоги: RPO/RTO, бюджет, «без змін коду», «serverless», регіони, шифрування. Правильна відповідь виконує **всі** вимоги одночасно.
- Відкидай неможливе: Deny-правило в Security Group, Gateway endpoint для SQS, WAF на NLB, читання з RDS Multi-AZ standby, EBS-том до інстансу в іншій AZ, Lambda на 2 години.
- Якщо є керований (managed) сервіс, варіант «напишемо свій скрипт на EC2 / cron» майже завжди неправильний.
- Два варіанти схожі — шукай одну відмінну деталь: Standard vs FIFO, Gateway vs Interface, User pool vs Identity pool, Compliance vs Governance.
- Час: ~2 хв на питання. Не впевнений — дай найкращу відповідь, познач *Flag for review* і йди далі. В кінці поверніться до позначених.
- В питаннях можуть бути старі назви: Kinesis Data Firehose = **Amazon Data Firehose**; QuickSight = **Amazon Quick**; Kinesis Data Analytics = **Managed Service for Apache Flink**; SageMaker = **SageMaker AI**; AWS SSO = **IAM Identity Center**; CloudWatch Events = **EventBridge**.

Ключові фрази в питаннях

Фраза в питанні	Що це означає
MOST cost-effective / LOWEST cost	Найдешевше, що виконує всі вимоги: Spot, lifecycle S3, serverless, Savings Plans, gateway endpoint
LEAST operational overhead / minimal management	Керований або serverless сервіс, мінімум компонентів, без власних скриптів і EC2
MOST secure / least privilege	Мінімальні права, IAM roles замість ключів, KMS, приватні підмережі, VPC endpoints
highly available	Кілька AZ: Multi-AZ, ASG у 2+ AZ + ALB

Фраза в питанні	Що це означає
fault tolerant	Працює без перерви навіть під час збою (надлишковість, active-active)
durable	Дані не загубляться: S3 (11 дев'яток), реплікація, бекапи
scalable / elastic	Auto Scaling, serverless, DynamoDB on-demand, Aurora Serverless
decouple / buffer / spikes	SQS між компонентами
real-time (мілісекунди, свої споживачі, replay)	Kinesis Data Streams
near real-time, доставка в S3/Redshift/OpenSearch без коду	Amazon Data Firehose
without code changes / minimal changes	RDS Proxy, Storage Gateway, EFS, Global Accelerator, MGN (lift-and-shift), Babelfish
temporary credentials	IAM Role + STS
static IP	NLB з Elastic IP або Global Accelerator
global users + static/dynamic web content	CloudFront
global users + TCP/UDP + fast regional failover	Global Accelerator
on-premises + low-latency access to cloud storage	Storage Gateway (локальний кеш)
migrate TBs/PBs over the network	DataSync
orchestrate / workflow / human approval	Step Functions

Основи: інфраструктура, модель відповідальності, Well-Architected

- **Region** — географічний регіон (напр., eu-central-1). Складається з кількох (зазвичай 3+) **Availability Zones (AZ)** — ізольованих дата-центрів з окремим живленням і мережею. Висока доступність = кілька AZ; захист від падіння всього регіону = кілька регіонів.
- **Edge locations** — точки CloudFront, Route 53 і Global Accelerator поруч з користувачами.
- **Local Zones** — AWS у великому місті (одноцифрові мс до користувачів). **Wavelength** — AWS всередині 5G-мережі оператора. **Outposts** — стійки AWS у твоєму дата-центрі.
- **Shared Responsibility Model:** AWS відповідає за безпеку **OF the cloud** (залізо, дата-центри, гіпервізор, керовані сервіси). Клієнт — за безпеку **IN the cloud** (дані, IAM, шифрування, Security Groups/NACL, патчі ОС на EC2, налаштування). На RDS і Lambda ОС патчить AWS, але доступи й дані — твоя відповідальність.
- **Well-Architected — 6 стовпів:** Operational Excellence, Security, Reliability, Performance Efficiency, Cost Optimization, Sustainability. Увесь іспит побудований на них.
- **Service Quotas** — ліміти сервісів. Soft-ліміти можна підняти. Для DR-регіону квоти треба підняти **заздалегідь**.

Well-Architected: принципи кожного стовпа (коротко)

- **Operational Excellence:** операції як код (IaC), часті малі зворотні зміни, передбачати збої, вчитися на кожному інциденті, спостережуваність (метрики, логи, трасування).
- **Security:** сильна основа ідентичності (least privilege, без довгострокових ключів), відстежуваність (логи, аудит), захист на **всіх** рівнях (мережа, інстанс, застосунок, дані), автоматизація безпеки, шифрування in transit і at rest, «тримати людей подалі від даних», готовність до інцидентів.

- **Reliability:** автоматичне відновлення після збоїв, тестування відновлення, горизонтальне масштабування замість одного великого ресурсу, «не вгадувати потужність» (Auto Scaling), зміни через автоматизацію.
- **Performance Efficiency:** використовувати готові керовані сервіси, «глобально за хвилини» (регіони, CloudFront), serverless, часті експерименти, обирати технологію під патерн доступу.
- **Cost Optimization:** фінансове керування хмарою, модель «плати за використане», вимірювати ефективність, не витрачати на «важку рутину» (керовані сервіси), розподіляти витрати (теги, акаунти).
- **Sustainability:** розуміти свій вплив, максимізувати завантаження ресурсів, нові ефективніші типи (напр., Graviton), керовані сервіси, менше зайвих даних і трафіку.

Тригери

Дані мають фізично лишатися у своєму дата-центрі, але потрібні сервіси AWS → **AWS Outposts**

Одноцифрова мс затримка для користувачів у конкретному місті → **AWS Local Zones**

Ультранизька затримка для мобільних пристроїв у 5G-мережі → **AWS Wavelength**

Перенести VMware-середовище без зміни інструментів → **VMware Cloud on AWS**

Хто патчить ОС на EC2? → **Клієнт (на RDS — AWS)**

Резервний регіон не зміг запустити потрібну кількість інстансів під час аварії → **Заздалегідь підняти Service Quotas у DR-регіоні**

4 IAM і керування доступом

- **IAM** — глобальний сервіс. Суб'єкти: users, groups (групи не вкладаються одна в одну), roles. Політика — JSON: Effect, Action, Resource, Condition (і Principal у resource-based).
- **Логіка оцінки:** явний **Deny** > явний **Allow** > неявний Deny (за замовчуванням заборонено все).
- **Root user:** лише для задач, які може тільки root. Увімкни MFA, не створюй access keys для root.
- **Least privilege** — мінімальні права. **IAM Access Analyzer** знаходить ресурси, відкриті зовнішнім акаунтам, і генерує політики з історії CloudTrail.
- **Ролі замість ключів:** EC2 → instance profile з роллю; Lambda → execution role; ECS → task role. Ніколи не зберігай access keys у коді чи на EC2.
- **STS** видає тимчасові облікові дані: `AssumeRole` (крос-акаунт, перемикання ролей), `AssumeRoleWithSAML` (корпоративний IdP), `AssumeRoleWithWebIdentity` (краще через Cognito).
- **Cross-account доступ:** роль в акаунті B з trust policy для акаунта A. Або **resource-based policy** на ресурсі (S3 bucket policy, KMS key policy, SQS/SNS policy, Lambda policy).
- **Permission boundary** — «стеля» прав для user/role. Дає делегувати: розробник може створювати ролі, але не ширші за межу.
- **Умови в політиках:** `aws:SourceIp`, `aws:RequestedRegion`, `aws:MultiFactorAuthPresent`, `aws:PrincipalOrgID` (доступ лише акаунтам твоєї організації), `aws:SecureTransport`. Теги + умови = **ABAC**.

- **AWS Organizations:** багато акаунтів в OU; **consolidated billing** (один рахунок, об'ємні знижки, спільні RI і Savings Plans).
 - **SCP** — обмежують максимум дозволів для акаунтів/OU. Самі **не дають** прав. **Не діють** на management account.
 - **RCP** (resource control policies, з 2024) — обмеження на ресурси в акаунтах, напр. «до S3 не може звертатися ніхто поза організацією».
 - Також tag policies, backup policies.
- **AWS Control Tower** — готова landing zone для багатьох акаунтів за best practices: Account Factory, controls/guardrails (preventive = SCP, detective = Config rules, proactive = CloudFormation hooks), централізовані логи.
- **IAM Identity Center** (колишній AWS SSO) — єдиний вхід співробітників у всі акаунти й бізнес-застосунки. Permission sets. Джерело користувачів: вбудоване, Active Directory або зовнішній IdP (Okta, Entra ID) через SAML 2.0 / SCIM.
- **AWS Directory Service:**
 - **Managed Microsoft AD** — справжній AD в AWS, trust з on-prem AD.
 - **AD Connector** — проксі до on-prem AD, нічого не зберігає в AWS.
 - **Simple AD** — дешевий Samba-сумісний, без trust, для малих середовищ.
- **Amazon Cognito:**
 - **User Pools** — реєстрація і вхід користувачів **застосунку** (email/пароль, соцмережі, SAML/OIDC), видає JWT-токени, інтеграція з ALB і API Gateway.
 - **Identity Pools** — видає **тимчасові AWS-credentials** користувачам (навіть гостям), щоб напряму працювати з S3, DynamoDB тощо.
- **AWS RAM** — ділитися ресурсами між акаунтами: підмережі (VPC sharing), Transit Gateway, правила Route 53 Resolver, конфігурації License Manager тощо.
- **IAM Access Advisor** (last accessed) — показує, якими сервісами роль чи користувач реально користувалися → прибрати зайві права.

- **IAM Roles Anywhere** — on-prem сервери отримують тимчасові AWS-credentials за X.509-сертифікатом, без довгострокових ключів.

Як AWS перевіряє доступ

1

Є явний Deny у будь-якій політиці? SCP/RCP, resource-based, permission boundary, identity-based

Так → ❌ DENY

↓ ні

2

SCP (і RCP) організації дозволяють дію? Діють на member-акаунти, але не на management account

Ні → ❌ DENY

↓ так

3

Permission boundary (якщо задана) дозволяє? Це «стеля» прав користувача або ролі

Ні → ❌ DENY

↓ так

4

Identity-based або resource-based policy дає Allow?

Так → ✅ ALLOW

↓ ні

5

Неявна заборона — за замовчуванням заборонено все

❌ DENY

Крос-акаунтний доступ: потрібен Allow і з боку того, хто звертається (IAM-політика в акаунті A), і з боку ресурсу (resource-based policy або trust policy ролі в акаунті B). У реальній логіці AWS є ще нюанси (session policies тощо), але для іспиту достатньо цієї схеми.

Приклади політик

Читання одного bucket. Зверни увагу: `s3:ListBucket` дається на ARN самого bucket, а `s3:GetObject` — на об'єкти (`/*`):

```
{
  "Version": "2012-10-17",
  "Statement": [
    { "Effect": "Allow", "Action": "s3:ListBucket", "Resource": "arn:aws:s3:"
    { "Effect": "Allow", "Action": "s3:GetObject", "Resource": "arn:aws:s3:"
  ]
}
```

Trust policy ролі для сторонньої компанії (акаунт 111122223333) із захистом від confused deputy:

```
{
  "Version": "2012-10-17",
  "Statement": [{
    "Effect": "Allow",
    "Principal": { "AWS": "arn:aws:iam::111122223333:root" },
    "Action": "sts:AssumeRole",
    "Condition": { "StringEquals": { "sts:ExternalId": "id-від-вендора" } }
  }]
}
```

Тригери

Застосунок на EC2 має читати S3 → **IAM role (instance profile)**, а не **access keys**

Дати іншому акаунту доступ до своїх ресурсів → **IAM role з trust policy + STS AssumeRole**

Заборонити всім акаунтам в OU вимикати CloudTrail або працювати поза дозволеними регіонами → **SCP**

Розробники можуть створювати ролі, але не ширші за певні права → **Permission boundary**

Швидко налаштувати багато акаунтів «правильно», з guardrails і логуванням → **AWS Control Tower**

Єдиний вхід співробітників у багато акаунтів AWS через корпоративний AD або Okta → **IAM Identity Center**

Реєстрація і вхід користувачів мобільного або веб-застосунку, вхід через соцмережі → **Cognito User Pool**

Користувачі мобільного застосунку мають завантажувати фото напряму в S3 → **Cognito Identity Pool (тимчасові credentials)**

Повноцінний AD в AWS з довірою (trust) до on-prem AD → **AWS Managed Microsoft AD**

Використати наявний on-prem AD без копіювання даних в AWS → **AD Connector**

Дозволити доступ до bucket лише акаунтам своєї організації → **Bucket policy з умовою aws:PrincipalOrgID**

Кілька акаунтів мають працювати в одній спільній VPC → **VPC sharing через AWS RAM**

Знайти ресурси, до яких мають доступ зовнішні акаунти → **IAM Access Analyzer**

Один рахунок і спільні знижки RI/Savings Plans на всі акаунти → **Organizations: consolidated billing**

Надавати доступ за тегами (відділ, проєкт) замість сотень політик → **ABAC (теги + умови)**

Стороння компанія (SaaS-вендор) отримує доступ до акаунта через роль, треба захист від confused deputy → **Роль з умовою sts:ExternalId y trust policy**

On-prem сервери мають отримувати тимчасові AWS-credentials без довгострокових ключів → **IAM Roles Anywhere**

Знайти й прибрати права, якими роль ніколи не користується → **IAM Access Advisor (last accessed) / IAM Access Analyzer**

Вимагати MFA для небезпечних дій (напр., видалення) → **Умова**
aws:MultiFactorAuthPresent у політиці

⚠ Пастки

SCP **не дає** дозволів, а лише обмежує. На management account SCP не діє.

`s3:ListBucket` — на ARN bucket, `s3:GetObject` / `s3:PutObject` — на `bucket/*`. Переплутаєш — буде AccessDenied.

Крос-акаунт через resource-based policy: потрібен Allow з **обох** боків (у політиці ресурсу і в IAM-політиці того, хто звертається).

Cognito **User Pool** = автентифікація (хто ти). **Identity Pool** = доступ до AWS (тимчасові ключі).

IAM Identity Center — для **співробітників**; Cognito — для **клієнтів** застосунку.

- **At rest** — шифрування KMS; **in transit** — TLS (HTTPS, сертифікати ACM).
- **AWS KMS** — керовані ключі, **регіональні**.
 - **AWS managed keys** (`aws/s3` , `aws/ebs`) — ротація щороку автоматично, керувати політикою не можна.
 - **Customer managed keys** — сам керуєш key policy, grants і ротацією: автоматично раз на 90–2560 днів (за замовчуванням 365) або вручну on-demand.
 - Symmetric (AES-256) і asymmetric (RSA/ECC — підпис, шифрування поза AWS).
- **Key policy** — головний контроль доступу до ключа. Cross-account: дозвіл у key policy + IAM-політика в іншому акаунті.
- **Envelope encryption**: KMS `Encrypt` шифрує максимум **4 KB**; великі дані шифрують data key (`GenerateDataKey`).
- **Multi-Region keys** — той самий ключ у кількох регіонах: зашифрував в одному, розшифрував в іншому. Без них при копіюванні снапшота в інший регіон його перешифровують ключем того регіону.
- **ThrottlingException від KMS** при масовій роботі з S3 (SSE-KMS) → **S3 Bucket Keys** (у разі менше викликів KMS і дешевше).
- **CloudHSM** — виділений (single-tenant) апаратний HSM. Ключі повністю під твоїм контролем, AWS до них доступу не має. FIPS 140 Level 3. Стандартні API (PKCS#11, JCE, CNG), Oracle TDE, SSL offload. Можна підключити до KMS як custom key store.
- **ACM (AWS Certificate Manager)**: безкоштовні публічні TLS-сертифікати для ELB, CloudFront, API Gateway; **автоматичне поновлення** (для DNS-валідації). Для **CloudFront** сертифікат має бути в регіоні **us-east-1**. Імпортовані сертифікати ACM сам не поновлює — стеж за терміном (події в EventBridge, Config rule).

- **Secrets Manager** — секрети + **автоматична ротація** (вбудована для RDS, Aurora, Redshift, DocumentDB; для решти — через Lambda), реплікація в інші регіони. Платно за кожен секрет.
- **SSM Parameter Store** — конфігурація і секрети (`SecureString` з KMS), ієрархія, standard tier безкоштовний. **Вбудованої ротації немає.**
- **EBS:** увімкни *encryption by default* для регіону. Незашифрований том → snapshot → copy snapshot з шифруванням → новий том.
- **RDS:** шифрування вмикається **тільки при створенні**. Незашифрована БД → snapshot → copy з шифруванням → restore. Read replica шифрується так само, як основна БД.
- **S3: SSE-S3** (за замовчуванням для всіх нових об'єктів з 2023), **SSE-KMS** (аудит використання ключа в CloudTrail + окремий контроль доступу до ключа), **DSSE-KMS** (двошарове), **SSE-C** (ключ надає клієнт, тільки HTTPS), шифрування на клієнті.
- **Примусити HTTPS до S3:** bucket policy з Deny, якщо `aws:SecureTransport = false`.
- **Видалення ключа KMS** — лише із затримкою 7–30 днів (за замовчуванням 30). Поки строк не минув, видалення можна скасувати. Безпечніша альтернатива — вимкнути (disable) ключ.
- **Key policy обов'язкова:** якщо вона не дозволяє акаунту делегувати доступ через IAM, IAM-політики до ключа не діють.
- **Зашифрований снапшот для іншого акаунта:** поділитися можна лише снапшотом, зашифрованим **customer managed key** (ділишся снапшотом і даєш доступ до ключа). Снапшот з AWS managed key спершу копіюють, перешифрувавши своїм ключем.
- **CloudHSM для НА** — кластер щонайменше з 2 HSM у різних AZ.

Тригери

Потрібен аудит, хто і коли використовував ключ шифрування даних у S3 → **SSE-KMS (викили ключа видно в CloudTrail)**

Ключі лише під твоїм контролем в апаратному модулі, FIPS 140 Level 3, AWS не має доступу → **CloudHSM**

Автоматично змінювати пароль до БД кожні 30 днів → **Secrets Manager (rotation)**

Дешево зберігати конфігурацію і рядки підключення без ротації → **SSM Parameter Store**

HTTPS на ALB або CloudFront без ручного поновлення сертифікатів → **ACM**

Шифрувати в одному регіоні й розшифровувати в іншому тим самим ключем → **KMS Multi-Region keys**

ThrottlingException від KMS при масовому завантаженні в S3 з SSE-KMS → **S3 Bucket Keys**

Зашифрувати наявну незашифровану RDS → **Snapshot** → **copy з шифруванням** → **restore**

Шифрувати через KMS файли більші за 4 KB → **Envelope encryption (data key)**

Заборонити HTTP-доступ і незашифровані завантаження в bucket → **Bucket policy з Deny та умовами**

Ключ має змінюватися частіше, ніж раз на рік → **Customer managed key з власним періодом ротації**

Поділитися зашифрованим снапшотом RDS/EBS з іншим акаунтом → **Customer managed KMS key + доступ до ключа для того акаунта**

Ключ KMS випадково запланували на видалення → **Скасувати видалення, поки не минув період очікування (7–30 днів)**

Пастки

На існуючій RDS або EBS не можна просто «увімкнути шифрування» — тільки через копію снапшота.

Сертифікат ACM для CloudFront — тільки в us-east-1 (для ALB — у регіоні ALB).

Класично (і на іспиті) публічний сертифікат ACM ставиться лише на інтегровані сервіси (ELB, CloudFront, API Gateway), а не прямо на EC2.

6 Сервіси безпеки: захист від атак і аудит

- **AWS WAF** — фایрвол рівня 7 (HTTP): SQL injection, XSS, блокування IP і країн (geo match), **rate-based rules** (ліміт запитів з одного IP), managed rule groups, Bot Control. Ставиться на **CloudFront, ALB, API Gateway, AppSync, Cognito User Pool, App Runner**. Не на **NLB** і не на **EC2**.
- **AWS Shield Standard** — безкоштовно й автоматично для всіх: DDoS рівнів 3–4.
- **AWS Shield Advanced** — платно (~\$3 000/міс на організацію): команда **SRT 24/7, захист від зростання рахунку** через DDoS, розширена детекція, захист рівня 7 разом з WAF. Для CloudFront, Route 53, Global Accelerator, ELB, EC2 Elastic IP.
- **AWS Firewall Manager** — централізовано керує правилами WAF, Shield Advanced, Security Groups, Network Firewall, DNS Firewall **у всіх акаунтах Organizations**. Нові акаунти і ресурси отримують правила автоматично.
- **AWS Network Firewall** — керований фایрвол на рівні VPC (stateful/stateless, IPS/IDS, фільтрація за доменами, правила Suricata). Часто — в окремій inspection VPC за Transit Gateway.
- **Route 53 Resolver DNS Firewall** — блокує DNS-запити з VPC до шкідливих доменів.
- **Amazon GuardDuty** — виявлення **загроз** за допомогою ML: аналізує CloudTrail, VPC Flow Logs, DNS-логи (+ S3, EKS, RDS, Lambda, runtime, сканування malware). Криптомайнінг, скомпрометовані ключі, зв'язок з C&C. Знахідки → EventBridge → автоматична реакція.
- **Amazon Inspector** — сканування **вразливостей** (CVE) і мережевої доступності: EC2, образи в ECR, Lambda. Працює безперервно.
- **Amazon Macie** — ML-пошук **чутливих даних** (PII, номери карток) у **S3**.
- **Amazon Detective** — **розслідування**: граф подій і першопричина знахідок GuardDuty.

- **AWS Security Hub** — єдина панель знахідок (GuardDuty, Inspector, Macie, Config, партнери) + перевірки стандартів (CIS, PCI DSS, AWS Foundational Security Best Practices).
- **AWS Artifact** — звіти відповідності AWS (SOC, PCI, ISO) і угоди (напр., БАА для HIPAA).
- **AWS Audit Manager** — автоматичний збір доказів для аудиту.
- **CloudTrail vs Config vs CloudWatch**: CloudTrail — **хто і коли** викликав API (аудит). Config — **яка конфігурація** ресурсу була і чи відповідає вона правилам (історія, compliance). CloudWatch — **метрики, логи, аларми** (продуктивність).
- **Багато акаунтів**: GuardDuty, Security Hub, Macie та Inspector вмикають централізовано через **delegated administrator** в AWS Organizations — нові акаунти підключаються автоматично.
- **Inspector знаходить, Patch Manager латає**: вразливості шукає Inspector, а патчі встановлює SSM Patch Manager.

Тригери

SQL injection, XSS, блокування країн на ALB або CloudFront → **AWS WAF**

Обмежити кількість запитів з одного IP (HTTP flood) → **WAF rate-based rule**

DDoS-захист + експерти 24/7 + компенсація витрат від атаки → **Shield Advanced**

Керувати правилами WAF і Security Groups у всіх акаунтах централізовано → **Firewall Manager**

Фільтрувати вихідний трафік VPC за доменними іменами, IPS для VPC → **AWS Network Firewall**

Незвичні API-виклики, криптомайнінг, скомпрометований інстанс → **GuardDuty**

Знайти вразливості (CVE) в EC2, образах ECR, Lambda → **Amazon Inspector**

Знайти PII або персональні дані в S3 → **Amazon Macie**

Знайти першопричину інциденту безпеки → **Amazon Detective**

Одна панель стану безпеки всіх акаунтів + перевірки CIS/PCI → **Security Hub**

Аудитору потрібен звіт SOC 2 або PCI від AWS → **AWS Artifact**

Хто видалив bucket або змінив Security Group? → **CloudTrail**

Перевіряти, що всі EBS-томи зашифровані, і бачити історію змін конфігурації → **AWS Config (+ автовиправлення через SSM Automation)**

Автоматично реагувати на знахідку GuardDuty (ізолювати інстанс) → **EventBridge rule → Lambda / SSM Automation**

Хтось зробив bucket публічним — треба автоматично виправити → **AWS Config rule + автовиправлення (SSM Automation) або EventBridge → Lambda**

Увімкнути GuardDuty в усіх акаунтах організації, включно з новими → **Delegated administrator в AWS Organizations**

Пастки


WAF не підтримує NLB. Для NLB: Shield Advanced від DDoS, фільтрація — Security Groups, NACL або Network Firewall.

GuardDuty = загрози, Inspector = вразливості, Macie = чутливі дані в S3. Їх часто плутають.

7 VPC і мережа

- **VPC** — приватна мережа в регіоні. IPv4 CIDR від /16 до /28. У кожній підмережі AWS резервує **5 IP-адрес** (перші 4 і останню).
- **Subnet** живе в **одній AZ**.
 - **Public subnet** — у route table є маршрут `0.0.0.0/0 → Internet Gateway (IGW)`.
 - **Private subnet** — маршруту на IGW немає; вихід в інтернет через **NAT Gateway**.
- **NAT Gateway** — керований, платно за годину + за кожен ГБ. Класичний (zonal) стоїть у public subnet; для HA — **по одному в кожній AZ** (інакше збій однієї AZ відріже інтернет усім, а трафік між AZ ще й коштує грошей).
- **NEW Regional NAT Gateway** (з листопада 2025) — один на VPC, сам розширюється на потрібні AZ, public subnet не потрібен. Іспит частіше питає класичну схему «NAT на кожен AZ».
- **NAT instance** — старий самокерований варіант (EC2, вимкнути Source/Destination check). Дешевший, але без HA і масштабування.
- **Egress-only Internet Gateway** — для **IPv6**: вихід в інтернет без вхідних з'єднань (аналог NAT для IPv6).
- **Security Group (SG)** — на рівні інстансу (ENI), **stateful** (відповідь дозволяється автоматично), **тільки Allow**. Можна посилатися на іншу SG як на джерело.
- **Network ACL (NACL)** — на рівні підмережі, **stateless** (треба окремо дозволити відповідь на ephemeral ports 1024–65535), є **Allow і Deny**, правила перевіряються за номером (від меншого, спрацьовує перше збігло).
- **Route table** — перемагає найспецифічніший маршрут (longest prefix match).

Схема типової VPC




Доступ до сервісів і з'єднання

- **VPC Endpoints** — доступ до сервісів AWS без інтернету і без NAT:
 - **Gateway endpoint** — тільки **S3 і DynamoDB**, безкоштовний, додається запис у route table.
 - **Interface endpoint (PrivateLink)** — ENI з приватним IP у підмережі. Майже всі сервіси (SQS, SNS, KMS, Secrets Manager, ECR, CloudWatch, S3...). Платно. Доступний з on-prem через VPN/Direct Connect.
 - **Endpoint policy** — обмежує, що можна робити через endpoint (напр., лише певні bucket).

- **AWS PrivateLink** — надати свій сервіс іншим VPC/акаунтам приватно: провайдер ставить **NLB** → endpoint service, споживач створює interface endpoint. Односторонній доступ, CIDR можуть перетинатися, масштабується на тисячі споживачів.
- **VPC Peering** — пряме з'єднання двох VPC (між акаунтами й регіонами). **Нетранзитивне** (A–B і B–C не дають A–C). CIDR **не можуть перетинатися**. Потрібно оновити route tables з обох боків.
- **Transit Gateway (TGW)** — хаб для сотень VPC, VPN і Direct Connect. **Транзитивна** маршрутизація, окремі route tables для сегментації, peering між регіонами, шариться через RAM, ECMP для VPN (сумує пропускну здатність тунелів), multicast.
- **Site-to-Site VPN** — IPsec-тунелі через інтернет: **Virtual Private Gateway (VGW)** або TGW на боці AWS + **Customer Gateway** на боці офісу. 2 тунелі для резерву. До 1,25 Gbps на тунель ( з листопада 2025 — тунелі до 5 Gbps на TGW). Налаштовується за хвилини.
 - **VPN CloudHub** — кілька офісів спілкуються між собою через VGW.
 - **Accelerated VPN** — через мережу Global Accelerator (лише з TGW).
- **Direct Connect (DX)** — виділений приватний канал до AWS. Dedicated: 1/10/100/400 Gbps. Hosted (через партнера): від 50 Mbps до 25 Gbps. Стабільна затримка, дешевший вихідний трафік. Прокладання — **тижні або місяці**.
 - **Не шифрується** сам по собі → **IPsec VPN поверх DX** або **MACsec**.
 - **Direct Connect Gateway** — один DX до багатьох VPC у різних регіонах.
 - Резервування: 2 DX у **різних DX-локаціях** (максимальна стійкість) або DX + Site-to-Site VPN як дешевий бекап.
 - VIF: private (до VPC), public (до публічних сервісів AWS), transit (до TGW).
- **AWS Client VPN** — доступ окремих співробітників (ноутбуків) до VPC (OpenVPN).

Схема гібридного з'єднання



Решта мережевих можливостей

- **VPC Flow Logs** — метадані IP-трафіку (хто, куди, порт, ACCEPT/REJECT) → CloudWatch Logs, S3 або Firehose. Вміст пакетів не пишуть (для цього — Traffic Mirroring).
- **Доступ до приватних EC2 без SSH: SSM Session Manager** (жодних відкритих портів, логування сесій) або EC2 Instance Connect Endpoint. Класичний варіант — bastion host у public subnet.

- **Гібридний DNS — Route 53 Resolver endpoints: Inbound** — on-prem сервери резолвлять приватні DNS-імена AWS; **Outbound** + forwarding rules — VPC резолвить on-prem домени.

Тригери

Інстанси в private subnet мають завантажувати оновлення з інтернету → **NAT Gateway у public subnet (для HA — по одному на AZ)**

Приватний EC2 звертається до S3 або DynamoDB без інтернету і безкоштовно → **Gateway VPC endpoint**

Приватний EC2 звертається до SQS, KMS, Secrets Manager без інтернету → **Interface VPC endpoint (PrivateLink)**

Великі рахунки за NAT Gateway через трафік до S3 → **Gateway endpoint для S3**

Заблокувати конкретну IP-адресу → **Network ACL з Deny (у Security Group Deny немає)**

БД має приймати трафік лише від вебсерверів → **SG бази з джерелом = SG вебсерверів**

Надати свій сервіс сотням клієнтських VPC приватно, CIDR перетинаються → **PrivateLink (NLB + endpoint service)**

З'єднати 2–3 VPC просто і дешево → **VPC Peering**

З'єднати десятки або сотні VPC і on-prem з транзитивною маршрутизацією → **Transit Gateway**

Швидко і дешево створити зашифрований канал до офісу → **Site-to-Site VPN**

Стабільна пропускна здатність, приватне з'єднання, великі обсяги даних → **Direct Connect**

Direct Connect + вимога шифрування → **IPsec VPN поверх DX (або MACsec)**

Недорогий резерв для Direct Connect → **Site-to-Site VPN як backup**

Максимальна стійкість гібридного з'єднання → **Кілька DX у різних DX-локаціях**

Один Direct Connect до VPC у кількох регіонах → **Direct Connect Gateway**

Віддалені співробітники підключаються до VPC → **AWS Client VPN**

Кілька філій мають спілкуватися між собою через AWS → **VPN CloudHub**

IPv6-інстанси виходять в інтернет, але недоступні ззовні → **Egress-only Internet Gateway**

Адмін-доступ до EC2 без відкритого порту 22 і з логуванням сесій → **SSM Session Manager**

On-prem сервери мають резолвити приватні DNS-імена в AWS → **Route 53 Resolver inbound endpoint**

VPC має резолвити внутрішні домени офісу → **Route 53 Resolver outbound endpoint + forwarding rule**

Проаналізувати відхилений трафік, хто стукає в інстанс → **VPC Flow Logs**

Дозволити через endpoint доступ лише до кількох «своїх» bucket → **VPC endpoint policy**

Пастки

Gateway endpoint — тільки S3 і DynamoDB. Для решти сервісів — Interface endpoint.

Gateway endpoint не працює для трафіку з on-prem (через VPN/DX) — для цього Interface endpoint.

VPC Peering нетранзитивний і неможливий при перетині CIDR.

У NAT Gateway немає Security Groups. Один NAT Gateway в одній AZ — єдина точка відмови.

Route 53

- Керований DNS + реєстрація доменів + health checks. SLA 100%.
- **Alias record** — вказує на ресурси AWS (ELB, CloudFront, S3 website, API Gateway, інший запис). Працює на **zone apex** (example.com). Запити до ресурсів AWS безкоштовні. **CNAME на apex не можна**.
- **Routing policies:**
 - **Simple** — один ресурс, без health checks.
 - **Weighted** — розподіл у відсотках (A/B-тести, поступова міграція, blue/green).
 - **Latency-based** — до регіону з найменшою затримкою для користувача.
 - **Failover** — active-passive: primary + secondary, перемикання за health check.
 - **Geolocation** — за країною/континентом користувача (мова, ліцензії, закони). Потрібен default-запис.
 - **Geoproximity** — за відстанню, з **bias** (змістити більше трафіку до певного регіону).
 - **Multivalued answer** — до 8 здорових записів (простий балансінг на клієнті, не заміна ELB).
 - **IP-based** — за CIDR клієнта (напр., за провайдером).
- **Health checks** перевіряють endpoint, інші health checks (calculated) або **CloudWatch alarm**. Приватні ресурси — лише через CloudWatch alarm, бо перевіральники Route 53 працюють з інтернету.
- **Private hosted zone** — DNS тільки всередині VPC (потрібні `enableDnsHostnames` і `enableDnsSupport`).
- **S3 static website через alias** — ім'я bucket має збігатися з доменом (bucket `example.com` для запису `example.com`).

CloudFront

- CDN: кешує контент на сотнях edge-локацій → менша затримка, менше навантаження на origin, дешевший трафік в інтернет.
- **Origins:** S3, ALB, EC2, API Gateway, будь-який HTTP-сервер (зокрема on-prem). **VPC origins** (з 2024) — приватні ALB/NLB/EC2 без публічного доступу.
- **Origin Access Control (OAC)** — bucket S3 доступний **лише через CloudFront**. OAC — сучасна заміна **OAI** (підтримує SSE-KMS).
- **Signed URL** — доступ до **одного** файлу. **Signed cookies** — до **багатьох** файлів (весь преміум-розділ) без зміни URL.
- **S3 presigned URL** — інша річ: тимчасовий доступ напряму до об'єкта S3 з правами того, хто підписав.
- **Geo restriction** — дозволити або заборонити країни.
- **Origin failover** — origin group (primary + secondary) при помилках 5xx/4xx.
- **Field-level encryption** — шифрує окремі поля форми (напр., номер картки) вже на edge.
- **CloudFront Functions** — легкий JS за мікросекунди (заголовки, редиректи, URL rewrite, прості перевірки токенів). **Lambda@Edge** — важча логіка, мережеві виклики, події origin request/response.
- **Cache behaviors** — різні правила кешу та origins за шаблоном шляху: `/static/*` → S3 з довгим кешем, `/api/*` → ALB без кешу.
- Кешування: TTL, cache policies, invalidation (краще версіонувати імена файлів).
- HTTPS: сертифікат ACM у **us-east-1**. Інтеграція з WAF і Shield.
- **Price classes** — обмежити набір edge-локацій, щоб платити менше.

Global Accelerator

- 2 статичні **anycast IP-адреси**. Трафік заходить у найближчу edge-точку і далі йде мережею AWS до endpoint (ALB, NLB, EC2, Elastic IP) в одному або кількох регіонах.

- Швидкий failover між регіонами (не залежить від DNS-кешу), health checks, traffic dials і ваги.
- **TCP і UDP, нічого не кешує.** Для ігор, IoT, VoIP або HTTP, коли потрібні статичні IP і швидке перемикання регіонів.

Тригери

Направити домен example.com (apex) на ALB → **Route 53 Alias record**

Поступово перевести 10% трафіку на нову версію → **Weighted routing**

Користувачі мають потрапляти до найшвидшого для них регіону → **Latency-based routing**

Active-passive DR між регіонами через DNS → **Failover routing + health checks**

Користувачі з Німеччини бачать німецьку версію / обмеження контенту за країною → **Geolocation routing**

Змістити більше трафіку до одного регіону → **Geoproximity routing (bias)**

Прискорити статичний і динамічний контент для глобальних користувачів → **CloudFront**

Заборонити прямий доступ до S3, лише через CloudFront → **OAC (Origin Access Control)**

Платний доступ підписників до багатьох відео → **CloudFront signed cookies**

Тимчасове посилання на один приватний файл → **CloudFront signed URL (або S3 presigned URL)**

Заблокувати доступ до контенту з певних країн → **CloudFront geo restriction (або WAF geo match)**

Статичні IP для глобального застосунку, UDP/ігри, швидкий failover регіонів → **Global Accelerator**

Легкі зміни заголовків і редиректи на edge → **CloudFront Functions**

Health check для приватного ресурсу → **CloudWatch alarm + Route 53 health check**

Автоматично показати сторінку-заглушку з S3, якщо основний сайт впав → **Route 53 failover на S3 static website (або CloudFront origin failover)**

Статика й API на одному домені через CloudFront, з різним кешуванням → **Cache behaviors за шляхом (/static/* → S3, /api/* → ALB)**

Пастки

CloudFront — кеш HTTP(S)-контенту. Global Accelerator — без кешу, TCP/UDP, статичні IP.

Route 53 failover залежить від TTL (клієнти кешують DNS). Global Accelerator перемикає швидше.

Elastic Load Balancing

- **ALB (рівень 7: HTTP/HTTPS/gRPC/WebSocket).** Маршрутизація за path (/api), host (api.example.com), заголовками, query string, методом, IP джерела. Targets: EC2, IP, **Lambda**, ECS (dynamic port mapping). Кілька сертифікатів через **SNI**. Автентифікація через Cognito/OIDC. Sticky sessions. Редирект HTTP→HTTPS. **Статичного IP немає.**
- **NLB (рівень 4: TCP/UDP/TLS).** Мільйони запитів/с, наднизька затримка, **статичний IP на кожен AZ (можна Elastic IP)**, зберігає IP клієнта, основа для **PrivateLink**. Підтримує Security Groups.
- **GWLB (рівень 3, протокол GENEVE, порт 6081).** Прозоро пропускає трафік через **віртуальні апарати сторонніх вендорів** (файрволи, IDS/IPS, DPI) і масштабує їх.
- **CLB** — застарілий, для нових рішень не обирають.
- **Cross-zone load balancing:** ALB — увімкнено за замовчуванням, безкоштовно. NLB/GWLB — вимкнено за замовчуванням, трафік між AZ платний.
- **Deregistration delay** (connection draining) — дочекатися завершення запитів перед виведенням цілі (за замовчуванням 300 с).
- TLS можна завершувати на ELB (сертифікат ACM). Для end-to-end шифрування — HTTPS і до targets.

Auto Scaling

- **ASG:** min / desired / max, **Launch Template** (Launch Configuration застаріла), кілька AZ, автоматична заміна нездорових інстансів.
- Health check за замовчуванням — статус EC2. **Увімкни ELB health check**, щоб ASG замінював інстанси, які «живі», але застосунок на них не відповідає.
- **Health check grace period** — час після запуску, коли ASG ще не перевіряє здоров'я (застосунок треба встигнути стартувати).

- **ELB access logs** → S3: хто, коли, який запит і з яким кодом відповіді.
- **Політики масштабування:**
 - **Target tracking** — тримати метрику на рівні (CPU 50%, запити на ціль ALB). Найпростіша і рекомендована.
 - **Step scaling** — різні кроки залежно від величини порушення аларму.
 - **Simple scaling** — одна дія + cooldown (застаріла).
 - **Scheduled** — за розкладом (відомий пік щопонеділка о 9:00).
 - **Predictive** — ML прогнозує циклічне навантаження і масштабує заздалегідь.
- **Воркери з черги SQS:** масштабуй за **backlog per instance** (`ApproximateNumberOfMessagesVisible` / кількість інстансів) через target tracking.
- **Cooldown / instance warmup** — пауза, поки новий інстанс не прогріється (default cooldown 300 с).
- **Lifecycle hooks** — дія під час запуску або видалення інстансу (встановити ПЗ, забрати логи перед термінацією).
- **Warm pools** — заздалегідь підготовлені інстанси для швидкого масштабування застосунків з довгим стартом.
- **Instance refresh** — поступово замінити всі інстанси на новий AMI / launch template.
- **Default termination policy (спрощено):** спершу AZ з найбільшою кількістю інстансів → інстанс з найстарішим launch template/configuration → найближчий до наступної години білінгу.
- **Mixed instances policy** — база On-Demand + Spot, кілька типів інстансів.
- **AWS Auto Scaling** (окремий сервіс) — масштабування кількох ресурсів разом: ASG, ECS, DynamoDB, репліки Aurora.

Тригери

Маршрутизувати `/api` і `/images` на різні групи серверів → **ALB path-based routing**

Кілька доменів з різними сертифікатами на одному балансувальнику → **ALB + SNI**

Статичний IP балансувальника (клієнт додає IP у whitelist) → **NLB з Elastic IP (або Global Accelerator)**

TCP/UDP, мільйони запитів, мінімальна затримка → **NLB**

Пропустити весь трафік через фایрвол-апарат стороннього вендора → **Gateway Load Balancer**

ALB бачить інстанс нездоровим, але ASG його не замінює → **Увімкнути ELB health check в ASG**

Відомий пік щопонеділка о 9:00 → **Scheduled scaling**

Щоденні циклічні піки, масштабуватися заздалегідь → **Predictive scaling**

Тримати середній CPU близько 50% → **Target tracking scaling**

Масштабувати воркерів за довжиною черги SQS → **Target tracking за backlog per instance**

Застосунок довго startує, масштабування запізнюється → **Warm pools (або AMI з уже встановленим ПЗ)**

Забрати логи з інстансу перед його видаленням при scale-in → **Lifecycle hook**

Користувач втрачає сесію, коли запит іде на інший сервер → **Sticky sessions (краще — сесії в ElastiCache або DynamoDB)**

Оновити всі інстанси ASG на новий AMI без простою → **Instance refresh**

Нові інстанси ASG одразу вважаються «нездоровими», бо застосунок довго startує → **Збільшити health check grace period**

Пастки

Для stateless-архітектури сесії зберігають в ElastiCache або DynamoDB, а не на самому інстансі.

ALB не дає статичного IP. Потрібен статичний IP — NLB або Global Accelerator.

10 EC2: інстанси, тарифи, розміщення

Типи інстансів

- **T / M** — загального призначення (T — burstable, накопичує CPU-кредити).
- **C** — compute optimized: пакетна обробка, кодування відео, HPC, ігрові сервери, ML-інференс на CPU.
- **R / X / z** — memory optimized: in-memory БД і кеші, SAP HANA, аналітика в пам'яті.
- **I / D / H** — storage optimized: дуже високі IOPS на локальних NVMe (OLTP, NoSQL, data warehouse).
- **P / G / Inf / Trn** — прискорювачі (GPU, ML).
- **Graviton** (літера g у назві, напр. m7g) — процесори ARM, помітно краща ціна/продуктивність.
- **Як читати назву:** m7g.2xlarge → сімейство **m**, покоління **7**, **g** = Graviton, розмір **2xlarge**. Інші літери: **a** — AMD, **i** — Intel, **d** — локальні NVMe-диски, **n** — посилена мережа.

Сховище і стан

- **Instance store** — локальні диски хоста: найвищі IOPS, але дані **зникають** при stop, terminate або збої хоста. Для кешу, буферів і тимчасових даних.
- **EBS root** — зберігається при stop.
- **Hibernate** — зберігає RAM на EBS root (том має бути зашифрований) → швидкий старт з «теплим» станом застосунку.
- **AMI** — регіональний образ. Для іншого регіону — **copy AMI**. «Golden AMI» з готовим ПЗ = швидкий старт при масштабуванні.
- **User data** — скрипт при першому запуску. **Instance metadata** — використовуй **IMDSv2** (токени).
- **Status checks:** *system* (проблема хоста AWS → **stop/start** переносить інстанс на інший хост або CloudWatch alarm з дією **recover**) vs *instance* (проблема в ОС → reboot, виправлення).

Мережа і розміщення

- **Placement groups:**

- **Cluster** — одна AZ, інстанси поруч: найменша затримка і найвища пропускна між ними (HPC). Ризик: все поруч.
 - **Spread** — кожен інстанс на окремому обладнанні; максимум **7 інстансів на AZ** у групі. Для кількох критичних інстансів.
 - **Partition** — групи стійок (до 7 partitions на AZ), сотні інстансів. Hadoop, Cassandra, Kafka.
- **EFA (Elastic Fabric Adapter)** — для HPC/MPI, обхід ОС, наднизька затримка між вузлами. **ENA** — розширена мережа (до 100+ Gbps).
 - **Elastic IP** — статична публічна IPv4 (з 2024 всі публічні IPv4 платні).
 - **ENI** — мережевий інтерфейс; його можна перечепити на інший інстанс (failover з тим самим приватним IP).

Тарифи (purchasing options)

- **On-Demand** — посекудна/погодинна оплата без зобов'язань. Короткі й непередбачувані навантаження.
- **Reserved Instances (RI)** — 1 або 3 роки, до ~72% знижки. **Standard RI** — більша знижка, сімейство змінювати не можна (можна продати на RI Marketplace). **Convertible RI** — можна міняти сімейство/ОС, знижка менша.
- **Savings Plans** — зобов'язання витратити \$/год протягом 1 або 3 років:
 - **Compute Savings Plan** — до ~66%, будь-яке сімейство, регіон, ОС + **Fargate і Lambda**.
 - **EC2 Instance Savings Plan** — до ~72%, конкретне сімейство в конкретному регіоні.
 -  **Database Savings Plans** (з грудня 2025) — до 35% на RDS, Aurora, DynamoDB, ElastiCache тощо (1 рік).

- **Spot** — до 90% знижки, але AWS може забрати інстанс з **попередженням за 2 хвилини**. Лише для переривних задач: batch, CI/CD, рендеринг, аналітика, stateless-вебсервери за ASG. Spot Fleet / EC2 Fleet, стратегія **price-capacity-optimized**.
- **Dedicated Hosts** — окремий фізичний сервер: видно сокети і ядра → **BYOL-ліцензії** (Windows Server, SQL Server, Oracle), вимоги комплаєнсу.
- **Dedicated Instances** — обладнання не ділиться з іншими клієнтами, але без контролю над хостом.
- **On-Demand Capacity Reservations** — гарантують ємність у конкретній AZ на будь-який термін, без знижки (знижку дають RI/Savings Plans поверх).

Тригери

Пакетні задачі, які можна переривати, мінімальна ціна → **Spot Instances**

Стабільне навантаження 24/7 на 1–3 роки → **Reserved Instances або Savings Plans**

Знижка + свобода міняти сімейство, регіон або перейти на Fargate/Lambda → **Compute Savings Plan**

Ліцензії прив'язані до фізичних ядер/сокетів (BYOL) → **Dedicated Hosts**

Гарантувати ємність в AZ на важливу подію без довгого зобов'язання → **On-Demand Capacity Reservation**

НРС, мінімальна затримка між вузлами → **Cluster placement group + EFA**

Кілька критичних інстансів не повинні відмовити разом → **Spread placement group**

Hadoop/Cassandra/Kafka на сотнях інстансів з ізоляцією стійок → **Partition placement group**

Найвищі IOPS для тимчасових даних або кешу → **Instance store**

Швидко відновити застосунок з «теплою» пам'яттю після зупинки → **EC2 Hibernate**

Інстанс не проходить system status check → **Stop/Start** або **CloudWatch alarm** → **recover**

In-memory застосунок, потрібно багато RAM → **R-сімейство (memory optimized)**

Кодування відео, наукові розрахунки → **C-сімейство (compute optimized)**

Швидкий запуск нових інстансів з готовим ПЗ → **Golden AMI**

Запустити той самий сервер в іншому регіоні → **Copy AMI в інший region**

Пастки

Spot не підходить для основної БД і критичних довгих задач без чекпоінтів.

Instance store не переживає stop. EBS переживає.

Вертикальне масштабування (більший тип інстансу) потребує зупинки; горизонтальне — додає інстанси через ASG.

11 Serverless і контейнери

AWS Lambda

- До **15 хвилин** на один виклик. Пам'ять **128 MB–10 240 MB** (CPU росте пропорційно пам'яті). `/tmp` — від 512 MB до 10 GB.
- Payload: **6 MB** синхронно (streamed response — до 200 MB), **1 MB** асинхронно. Пакет коду: 50 MB zip / 250 MB розпакований; container image — до 10 GB; до 5 layers.
- **Concurrency**: за замовчуванням 1 000 одночасних виконань на region (можна підняти).
 - **Reserved concurrency** — гарантує функції частку і водночас обмежує її (захист БД від перевантаження).
 - **Provisioned concurrency** — заздалегідь прогріті середовища → **немає cold start**.
 - **SnapStart** — швидкий старт для Java, Python, .NET.
- Тригери: API Gateway, ALB, S3 events, SQS, SNS, EventBridge, DynamoDB Streams, Kinesis, Cognito, CloudFront (Lambda@Edge).
- **Lambda у VPC** — доступ до приватних RDS/ElastiCache. Інтернет — тільки через NAT Gateway. Забагато з'єднань до RDS → **RDS Proxy**.
- Асинхронні виклики: повтори, **DLQ** або **Destinations** (успіх/помилка → SQS, SNS, EventBridge, Lambda).
- **Версії й aliases**: alias може ділити трафік між двома версіями (напр., 90/10) для поступового релізу.
- **Lambda + SQS**: visibility timeout черги ставлять щонайменше в 6 разів більшим за timeout функції; невдалі повідомлення — у DLQ.
- Довше 15 хвилин → розбити через Step Functions, або ECS/Fargate, або AWS Batch.

Amazon API Gateway

- **REST API** — повний функціонал: кешування, API keys + **usage plans**, WAF, валідація запитів. **HTTP API** — дешевше і простіше (JWT-авторизація). **WebSocket API** — двосторонній зв'язок (чати, реальний час).
- Типи endpoint: Edge-optimized (через CloudFront), Regional, **Private** (лише з VPC через interface endpoint).
- **Throttling**: за замовчуванням 10 000 запитів/с на акаунт у регіоні (burst 5 000); usage plans — окремі ліміти для клієнтів; при перевищенні — помилка 429.
- Таймаут інтеграції за замовчуванням **29 с** (для Regional і Private REST API можна збільшити). Payload до 10 MB.
- Авторизація: IAM, **Cognito User Pools**, **Lambda authorizer** (власна логіка перевірки токенів).
- **Stages** (dev, prod) і **canary deployment** — частина трафіку йде на нову версію API.

Контейнери та інша обчислювальна платформа

- **Amazon ECS** — оркестрація контейнерів від AWS (простіше за Kubernetes).
 - Launch type **EC2** — сам керуєш інстансами (дешевше при стабільному навантаженні, GPU, особливі вимоги).
 - Launch type **Fargate** — serverless, без серверів.
 - Task definition, service, **task IAM role** (права саме для контейнера), ALB з dynamic port mapping.
- **Amazon EKS** — керований **Kubernetes**: коли вже використовують K8s, потрібна портативність або open-source інструменти. Managed node groups, Fargate profiles, EKS Auto Mode.
- **ECS Anywhere / EKS Anywhere / EKS Distro** — запуск на власних серверах on-prem.
- **AWS Fargate** — serverless для контейнерів (ECS і EKS): платиш за vCPU і пам'ять задачі, EC2 не керуєш.

- **Amazon ECR** — приватний реєстр образів: сканування вразливостей, реплікація між регіонами.
- **Elastic Beanstalk** — PaaS: завантажуєш код (Java, .NET, Node.js, Python, PHP, Go, Docker), Beanstalk сам створює EC2, ASG, ELB і моніторинг. Політики розгортання: all at once, rolling, rolling with additional batch, **immutable**, traffic splitting, **blue/green** (swap URL).
- **AWS Batch** — пакетні задачі будь-якої тривалості на EC2, Spot або Fargate; черги й планувальник задач.
- **Serverless Application Repository** — готові serverless-застосунки для швидкого розгортання.

Тригери

Задача виконується 40 хвилин → **Не Lambda: AWS Batch, ECS/Fargate або розбити через Step Functions**

Cold start критичний для API на Lambda → **Provisioned concurrency (для Java — SnapStart)**

Lambda вичерпує з'єднання до RDS → **RDS Proxy**

Обмежити кількість одночасних виконань функції → **Reserved concurrency**

Обробити зображення одразу після завантаження в S3 → **S3 event → Lambda**

Serverless REST API → **API Gateway + Lambda (+ DynamoDB)**

Різні ліміти запитів для різних клієнтів API, API keys → **API Gateway usage plans + throttling**

Двосторонній чат у реальному часі → **API Gateway WebSocket API**

Власна перевірка токенів доступу до API → **Lambda authorizer**

Контейнери без керування серверами → **Fargate (ECS або EKS)**

Компанія вже використовує Kubernetes → **Amazon EKS (on-prem — EKS Anywhere)**

Розробники хочуть просто задеплоїти веб-застосунок без роботи з інфраструктурою → **Elastic Beanstalk**

Нова версія з мінімальним ризиком і швидким відкатом → **Blue/green (Beanstalk swap URL або Route 53 weighted)**

Тисячі пакетних задач з чергами і Spot → **AWS Batch**

Контейнеру потрібен доступ до S3 → **ECS task IAM role**

Перенести застосунок у контейнери без переписування коду → **Образ у ECR + ECS/EKS на Fargate**

Функція має реагувати на нові записи в DynamoDB → **DynamoDB Streams → Lambda**

Поступово випустити нову версію Lambda на 10% трафіку → **Lambda alias з вагами (weighted alias)**

Lambda читає SQS, і повідомлення обробляються повторно → **Visibility timeout черги $\geq 6 \times$ timeout функції**

⚠ Пастки

Lambda — максимум 15 хвилин. Усе довше — не Lambda.

Beanstalk не «serverless»: він створює EC2, просто керує ними за тебе.

Лише зміна пам'яті Lambda збільшує і CPU (окремо CPU не налаштовується).

12 Інтеграція і повідомлення: SQS, SNS, EventBridge, Step Functions, MQ

Amazon SQS


- Керована черга, **pull**-модель: споживачі самі забирають повідомлення. Розв'язує компоненти (decoupling) і згладжує піки (buffer).
- **Standard**: майже необмежена пропускна здатність, **at-least-once** (можливі дублікати), порядок не гарантується.
- **FIFO**: суворий порядок у межах **MessageGroup**Id, **exactly-once processing** (дедуплікація за 5 хв), 300 викликів/с (3 000 повідомлень/с з батчами по 10), high-throughput режим — у рази більше. Назва черги закінчується на `.fifo`.
- Повідомлення до **1 MiB** (з серпня 2025; раніше 256 KB). Більші — **Extended Client Library** (до 2 GB через S3).
- Зберігання: від 1 хв до **14 днів** (за замовчуванням 4 дні).
- **Visibility timeout** — поки один споживач обробляє повідомлення, інші його не бачать (30 с за замовчуванням, максимум 12 год). Обробка довша за timeout → повідомлення оброблять двічі → **збільш visibility timeout**.
- **Long polling** (`waitTimeSeconds` до 20 с) — менше порожніх відповідей, дешевше.
- **Delay queue** — затримати доставку до 15 хв.
- **Dead-letter queue (DLQ)** — «отруйні» повідомлення після N невдалих спроб (`maxReceiveCount`) для аналізу.
- Споживач сам видаляє повідомлення (`DeleteMessage`) після успішної обробки.

Amazon SNS

- Pub/sub, **push**: одне повідомлення → багато підписників (SQS, Lambda, HTTP/S, email, SMS, мобільні push, Firehose).
- **Fan-out**: SNS topic → кілька SQS-черг, кожна система обробляє незалежно.

- **Message filtering** — підписник отримує лише потрібні повідомлення (filter policy).
- SNS FIFO topic → SQS FIFO (порядок + без дублікатів).
- Повідомлення до 256 KB (NEW з вересня 2026 можна до 1 MiB через налаштування `MaximumMessageSize`).
- Щоб SNS або S3 могли писати в SQS, потрібна **queue policy** (resource-based), що дозволяє їм `sqs:SendMessage` .

Схема: подієва архітектура



Amazon EventBridge

- Шина подій: події від сервісів AWS, власних застосунків і **SaaS-партнерів** (Zendesk, Datadog, Shopify...) → правила з **event pattern** → цілі (Lambda, SQS, Step Functions тощо). Колишні CloudWatch Events.
- **EventBridge Scheduler / cron** — serverless-запуск задач за розкладом.
- Archive & replay, schema registry, cross-account шини, **Pipes** (джерело → фільтр/збагачення → ціль).

AWS Step Functions

- Оркестрація кроків (state machine): послідовність, розгалуження, паралельність, **retry/catch**, очікування, **людське схвалення** (callback з task token).
- **Standard** — до 1 року, exactly-once, повна історія виконання (довгі бізнес-процеси).
- **Express** — до 5 хвилин, великі обсяги подій, at-least-once, дешевше.
- Прямі інтеграції з сотнями сервісів без Lambda-«клею». Distributed Map — масова паралельна обробка об'єктів S3.

Amazon MQ і AppFlow

- **Amazon MQ** — керований **ActiveMQ** або **RabbitMQ**. Для міграції наявних застосунків, що використовують стандартні протоколи (**JMS, AMQP, MQTT, STOMP, OpenWire**), без переписування коду. Нові застосунки — SQS/SNS.
- **Amazon AppFlow** — перенесення даних між SaaS (Salesforce, SAP, ServiceNow, Zendesk, Slack) і S3/Redshift без коду, за розкладом або подією.

Що обрати

Потреба	Сервіс
Черга між компонентами, воркери самі забирають задачі	SQS
Одне повідомлення → багато одержувачів (push)	SNS (fan-out → SQS)
Маршрутизація подій за вмістом, SaaS-події, розклад	EventBridge

Потреба	Сервіс
Суворий порядок і без дублікатів	SQS FIFO / SNS FIFO
Потік даних у реальному часі, кілька споживачів, replay	Kinesis Data Streams
Багатокроковий процес з помилками, повторами, схваленням	Step Functions
Міграція з on-prem брокера (JMS/AMQP/MQTT)	Amazon MQ

Тригери

Розв'язати компоненти, замовлення не повинні губитися при піках → **SQS**

Обробка суворо по порядку і без дублікатів (фінансові транзакції) → **SQS FIFO**

Одне повідомлення мають обробити кілька незалежних систем → **SNS fan-out** → **кілька SQS**

Повідомлення обробляються двічі → **Збільшити visibility timeout**

Повідомлення, які постійно падають з помилкою → **Dead-letter queue**

Зменшити кількість порожніх ReceiveMessage і витрати → **Long polling**

Повідомлення більші за 1 MiB → **SQS Extended Client Library + S3**

Реагувати на подію від SaaS-партнера або маршрутизувати події за правилами → **EventBridge**

Запускати Lambda щоночі о 2:00 → **EventBridge Scheduler (cron)**

Багатокроковий процес з повторами і ручним схваленням → **Step Functions (Standard)**

Мільйони коротких подій на секунду в workflow → **Step Functions Express**

Мігрувати застосунок на RabbitMQ/ActiveMQ без переписування → **Amazon MQ**

Регулярно вивантажувати дані з Salesforce у S3 без коду → [Amazon AppFlow](#)

Різні підписники мають отримувати лише свої типи повідомлень → [SNS message filtering](#)

Пастки

SQS не видаляє повідомлення після читання автоматично — споживач викликає `DeleteMessage` .

SNS не зберігає повідомлення. Для надійної обробки став SQS за SNS.

SQS Standard може доставити повідомлення двічі і не за порядком.

13 Amazon S3 і Glacier

Основне

- Об'єктне сховище, durability **11 дев'яток** (99,999999999%). Bucket — регіональний, але ім'я глобально унікальне.
- Об'єкт до **50 TB** ( з грудня 2025; раніше 5 TB — на іспиті може трапитися стара цифра).
- Один PUT — до 5 GB. **Multipart upload** рекомендований від 100 MB і обов'язковий понад 5 GB: частини вантажаться паралельно, збірні частини — повторно.
- **Strong read-after-write consistency** для всіх операцій.
- **Продуктивність**: 3 500 PUT/COPY/POST/DELETE і 5 500 GET/HEAD запитів/с **на кожен префікс** → більше префіксів = більше швидкості.
- **Transfer Acceleration** — швидке завантаження з далеких країн через edge-локації. **Byte-range fetches** — паралельне читання частин файлу.

Класи зберігання

Клас	Для чого	Мін. термін оплати	Доступ
Standard	Часті звернення	—	мс
Intelligent-Tiering	Невідомий або змінний патерн доступу	—	мс (архівні рівні — години); плата за моніторинг, без плати за отримання
Express One Zone	Найшвидший, 1 AZ, одноцифрові мс, directory buckets	1 година	мс
Standard-IA	Рідко, але потрібні миттєво	30 днів	мс, плата за ГБ отримання
One Zone-IA	Рідко, дані можна відтворити, 1 AZ	30 днів	мс, плата за ГБ отримання
Glacier Instant Retrieval	Архів, доступ ~раз на квартал, але миттєво	90 днів	мс

Клас	Для чого	Мін. термін оплати	Доступ
Glacier Flexible Retrieval	Архів і бекапи	90 днів	Expedited 1–5 хв, Standard 3–5 год, Bulk 5–12 год (безкоштовно)
Glacier Deep Archive	Найдешевше, зберігання 7–10+ років	180 днів	Standard до 12 год, Bulk до 48 год

- Мінімальний розмір об'єкта для оплати в Standard-IA, One Zone-IA і Glacier Instant Retrieval — 128 KB.
- Intelligent-Tiering сам переносить об'єкти: 30 днів без доступу → Infrequent, 90 днів → Archive Instant; опційно — Archive Access і Deep Archive Access.
- **Provisioned capacity** для Glacier Flexible Retrieval гарантує, що Expedited-відновлення (1–5 хв) спрацює навіть у пікові періоди.

S3 Standard

0–30 днів: часті звернення



Standard-IA

після 30 днів: рідко, але миттєво



Glacier Instant / Flexible

після 90 днів: архів (мс або хвилини–години)



Glacier Deep Archive

після 180 днів: найдешевше, відновлення до 12–48 год



Expiration

видалення через N років

Строки — лише приклад. У Standard-IA можна перевести не раніше ніж через 30 днів; кожен клас має мінімальний строк оплати (30 / 90 / 180 днів). Невідомий патерн доступу — просто Intelligent-Tiering.

Керування даними

- **Lifecycle rules** — автоматичні переходи між класами (transition) і видалення (expiration), зокрема для старих версій і незавершених multipart-завантажень. У Standard-IA/One Zone-IA можна перевести не раніше ніж через 30 днів після створення.
- **Versioning** — захист від перезапису і видалення (видалення = delete marker, стару версію можна повернути). **MFA Delete** — для остаточного видалення версій потрібен MFA (вмикає тільки root).

- **Replication: CRR** (в інший регіон: DR, менша затримка, комплаєнс) і **SRR** (в тому ж регіоні: збір логів, prod → test). Потрібен versioning з обох боків. Реплікуються лише нові об'єкти; наявні — через **S3 Batch Replication**. **RTC** — 99,99% об'єктів за 15 хв (SLA).
- **Object Lock (WORM):**
 - **Compliance mode** — ніхто, навіть root, не видалить і не змінить до кінця терміну.
 - **Governance mode** — можуть обійти користувачі з окремим дозволом.
 - **Legal hold** — без терміну, доки не знімуть.
- **S3 Glacier Vault Lock** — WORM-політика для vault. (Окремий старий сервіс «Amazon Glacier» з vaults з листопада 2025 закритий для нових клієнтів; класи S3 Glacier працюють як завжди.)

Безпека і доступ

- **Block Public Access** увімкнено за замовчуванням. ACL вимкнені за замовчуванням (Object Ownership = *Bucket owner enforced*). Доступ — через **bucket policy** та IAM.
- **Presigned URL** — тимчасовий доступ до приватного об'єкта (завантажити або скачати) з правами того, хто підписав.
- **Access Points** — окремі точки доступу зі своїми політиками для різних команд і застосунків (можна «тільки з VPC»).
- **Multi-Region Access Points** — один глобальний endpoint до bucket у кількох регіонах з маршрутизацією і failover.
- **CORS** — дозволити браузеру з іншого домену звертатися до bucket.
- **aws:SourceVpc / aws:SourceVpc** в bucket policy — доступ лише через конкретний VPC endpoint або з конкретної VPC.

Приклад bucket policy: заборонити HTTP і будь-який доступ не через свій VPC endpoint (обережно: друге правило закриє доступ навіть з консолі):

```
{
  "Version": "2012-10-17",
  "Statement": [
    {
      "Sid": "DenyHTTP", "Effect": "Deny", "Principal": "*", "Action": "s3:*",
      "Resource": ["arn:aws:s3::my-bucket", "arn:aws:s3::my-bucket/*"],
      "Condition": { "Bool": { "aws:SecureTransport": "false" } }
    },
    {
      "Sid": "OnlyMyEndpoint", "Effect": "Deny", "Principal": "*", "Action":
      "Resource": ["arn:aws:s3::my-bucket", "arn:aws:s3::my-bucket/*"],
      "Condition": { "StringNotEquals": { "aws:SourceVpce": "vpce-1a2b3c4d" }
    }
  ]
}
```

Інші можливості

- **Event notifications** — при створенні або видаленні об'єктів → SNS, SQS, Lambda, **EventBridge** (більше цілей і фільтрів).
- **Static website hosting** — лише HTTP. Для HTTPS і власного домену → **CloudFront + OAC** (bucket лишається приватним).
- **Requester Pays** — за завантаження даних платить той, хто завантажує.
- **S3 Batch Operations** — одна дія над мільярдами об'єктів (копіювання, теги, restore, виклик Lambda).
- **S3 Inventory і Storage Lens** — звіти про об'єкти та аналітика використання і витрат.
- **Storage Class Analysis** — аналізує, як часто читають дані, і підказує, коли переводити їх у Standard-IA (основа для lifecycle-правил).
- S3 Select і S3 Object Lambda закриті для нових клієнтів (замість Select використовувати Athena).

Тригери

Невідомий або змінний патерн доступу, без ручного керування → **S3 Intelligent-Tiering**

Дані читають рідко, але потрібні миттєво → **S3 Standard-IA (раз на квартал — Glacier Instant Retrieval)**

Відтворювані дані (мініатюри, копії), рідко, найдешевше з мс-доступом → **S3 One Zone-IA**

Архів, іноді потрібен доступ за кілька хвилин → **Glacier Flexible Retrieval (Expedited)**

Зберігати 7–10 років для регулятора, доступ до 48 год прийнятний, найдешевше → **Glacier Deep Archive**

Автоматично перенести в Glacier через 90 днів і видалити через 5 років → **Lifecycle rule**

Захист від випадкового видалення або перезапису → **Versioning (+ MFA Delete)**

Ніхто не може видалити або змінити дані N років (WORM, регулятор) → **S3 Object Lock, Compliance mode**

Копія bucket в іншому регіоні для DR → **Cross-Region Replication (наявні об'єкти — Batch Replication)**

Користувачі з різних континентів повільно завантажують великі файли → **S3 Transfer Acceleration + multipart upload**

Файли понад 100 MB, нестабільна мережа → **Multipart upload**

Тимчасово дати клієнту завантажити або скачати приватний файл → **Presigned URL**

Багато команд, різні права до одного великого bucket → **S3 Access Points**

Запустити обробку, щойно файл з'явився в bucket → **S3 Event Notification → Lambda / SQS / EventBridge**

Партнери завантажують великі датасети — хай самі платять за трафік → **Requester Pays**

Статичний сайт з HTTPS і власним доменом → **S3 + CloudFront (OAC) + ACM + Route 53**

Дуже високий темп запитів до S3 → **Розподілити ключі по кількох префіксах**

Найнижча затримка S3 для ML/аналітики в одній AZ → **S3 Express One Zone**

Змінити клас або теги мільйонів наявних об'єктів → **S3 Batch Operations**

Доступ до bucket лише з конкретної VPC або через конкретний endpoint → **Bucket policy з умовою aws:SourceVpce (або aws:SourceVpc)**

Гарантувати швидке (Expedited) відновлення з Glacier у будь-який момент → **Provisioned capacity**

Вирішити, коли переводити дані в IA, на основі реального доступу → **S3 Storage Class Analysis**

Пастки

S3 не можна «змонтувати» як диск для БД — це об'єктне сховище, а не блочне.

One Zone-IA і Express One Zone зберігають дані в одній AZ — при втраті AZ дані можуть зникнути.

Видалення з IA/Glacier раніше мінімального терміну однаково оплачується за весь мінімум.

Amazon EBS

Тип	Макс. IOPS	Макс. пропускна	Для чого
gp3 (SSD)	3 000 базово, до 80 000	125 MiB/s базово, до 2 000 MiB/s	За замовчуванням: boot, більшість застосунків. IOPS і пропускна налаштовуються окремо від розміру
gp2 (SSD)	3 IOPS на GiB (малі томи — burst до 3 000), максимум 16 000	до 250 MiB/s	Старший тип, IOPS прив'язані до розміру
io2 Block Express (SSD)	до 256 000	до 4 000 MiB/s	Критичні БД, затримка < 1 мс, durability 99,999%, Multi-Attach
io1 (SSD)	до 64 000	до 1 000 MiB/s	Старший Provisioned IOPS
st1 (HDD)	500	500 MiB/s	Big data, логи, DWH — послідовне читання. Не boot
sc1 (HDD)	250	250 MiB/s	Холодні дані, найдешевше. Не boot

- Розміри: gp3 і io2 — до 64 TiB (gp3 так з вересня 2025; раніше 16 TiB і 16 000 IOPS).
- EBS прив'язаний до **однієї AZ**. Перенести в іншу AZ або регіон → **snapshot** → створити том там (snapshot можна копіювати між регіонами).
- Snapshots — інкрементальні, зберігаються в S3. Автоматизація: **Data Lifecycle Manager (DLM)** або **AWS Backup. Snapshot Archive** — дешевше для рідко потрібних. **Recycle Bin** — захист від випадкового видалення. **Fast Snapshot Restore** — том одразу на повній швидкості.
- **Multi-Attach** (лише io1/io2) — один том до кількох Nitro-інстансів в одній AZ (кластерні застосунки).

- **Elastic Volumes** — змінити тип, розмір або IOPS тому без зупинки інстансу. Тому gp2 → gp3 — зазвичай дешевше і без простою.

Amazon EFS

- Керована **NFS**-файлова система для **Linux**: одночасно для тисяч EC2, ECS, EKS і Lambda, **у кількох AZ** (або One Zone — дешевше).
- Роста автоматично до петабайтів, платиш за використане.
- Класи: Standard, **Infrequent Access**, **Archive** + lifecycle management.
- Throughput: **Elastic** (рекомендовано), Provisioned, Bursting. Performance mode — General Purpose.
- Шифрування, POSIX-права, Access Points, реплікація в інший регіон. Дорожча за EBS за ГБ, зате спільна.
- **Mount target** створюють у кожній AZ; його Security Group має дозволяти **NFS**, **порт 2049** від клієнтів.

Amazon FSx

- **FSx for Windows File Server** — **SMB**, NTFS, інтеграція з **Active Directory**, DFS, Multi-AZ. Для Windows-застосунків, SharePoint, домашніх папок.
- **FSx for Lustre** — високопродуктивна ФС для **HPC**, **ML**, **рендерингу**, **фінансових моделей**: сотні GB/s, суб-мс затримка, **інтеграція з S3** (читає дані з S3, пише результати назад). Scratch (тимчасово, дешево) vs Persistent (довготривало, з реплікацією).
- **FSx for NetApp ONTAP** — **NFS + SMB + iSCSI** одночасно, Linux/Windows/macOS, snapshots, клонування, дедуплікація і компресія. Міграція з NetApp.
- **FSx for OpenZFS** — міграція ZFS/Linux NFS, snapshots, низька затримка.

Тригери

Спільна файлова система для кількох Linux-інстансів у різних AZ → **Amazon EFS**

Спільна файлова система для Windows з Active Directory → **FSx for Windows File Server**

НРС або ML, дуже висока продуктивність, дані лежать у S3 → **FSx for Lustre**

Потрібні NFS і SMB одночасно / міграція з NetApp → **FSx for NetApp ONTAP**

БД на EC2 потребує понад 100 000 стабільних IOPS → **io2 Block Express**

Дешевий диск для великих послідовних логів і big data → **st1**

Найдешевший блочний диск для холодних даних → **sc1**

Знизити витрати на EBS без простою → **gp2 → gp3**

10 000 IOPS на невеликому томі дешево → **gp3 (IOPS окремо від розміру)**

Перенести EBS-том в іншу AZ → **Snapshot → новий том в іншій AZ**

Щоденні автоматичні знімки EBS з видаленням старих → **Data Lifecycle Manager або AWS Backup**

Кластерний застосунок на кількох інстансах з одним спільним томом → **EBS Multi-Attach (io1/io2)**

Файли в EFS майже не відкривають після 30 днів → **EFS lifecycle → Infrequent Access / Archive**

EC2 не можуть змонтувати EFS (timeout) → **Дозволити порт 2049 (NFS) у Security Group mount target**

Тимчасовий кеш з максимальними IOPS → **Instance store**

Пастки

EBS — одна AZ і, як правило, один інстанс. EFS — багато інстансів, багато AZ, тільки Linux (NFS).

HDD-томи (st1, sc1) не можуть бути boot-томом.

Для Windows-шар — FSx for Windows, а не EFS.

Storage Gateway (on-prem доступ до хмарного сховища з локальним кешем)

- **S3 File Gateway** — NFS/SMB-шари, файли стають об'єктами в S3 (далі lifecycle, Glacier).
- **FSx File Gateway** — локальний кеш для FSx for Windows (з жовтня 2024 недоступний новим клієнтам).
- **Volume Gateway (iSCSI)**:
 - **Cached** — основні дані в S3, «гарячі» — локально.
 - **Stored** — усі дані локально, асинхронний бекап в S3 (як EBS snapshots).
- **Tape Gateway** — віртуальна стрічкова бібліотека (VTL) для наявного бекап-ПЗ → S3 / Glacier. Заміна фізичних стрічок.

Перенесення даних

- **AWS DataSync** — **онлайн**-перенесення і синхронізація великих обсягів: NFS, SMB, HDFS, об'єктні сховища, інші хмари ↔ S3, EFS, FSx. Агент on-prem, шифрування, перевірка цілісності, збереження метаданих і прав, розклад, обмеження пропускнуої. Також між сервісами AWS.
- **AWS Transfer Family** — керований **SFTP / FTPS / FTP / AS2**-сервер поверх S3 або EFS. Партнери працюють як раніше, нічого не змінюючи.
- **Snow Family (Snowball Edge)** — фізичні пристрої для **офлайн**-перенесення терабайтів і петабайтів і для edge-обчислень, коли мережа повільна або дорога.
 - Орієнтир: якщо передача мережею займе більше ~тижня → фізичний пристрій.
 -  З 7.11.2025 Snowball Edge **недоступний новим клієнтам**. AWS радить DataSync, **Data Transfer Terminal** (фізичні локації AWS для швидкого завантаження) або партнерів. На іспиті Snowball ще може бути правильною відповіддю.

Міграція серверів і баз даних

- **AWS DMS** — міграція БД з мінімальним простоем: джерело працює під час міграції, **CDC** (безперервна реплікація змін).
 - **Гомогенна** (MySQL → Aurora MySQL, Oracle → RDS Oracle) — DMS або нативні інструменти.
 - **Гетерогенна** (Oracle → Aurora PostgreSQL, SQL Server → MySQL) — спершу конвертація схеми **SCT / DMS Schema Conversion**, потім дані через DMS.
 - Також з/у S3, Kinesis, DynamoDB, Redshift.
 - SCT конвертує і схеми **сховищ даних** (Oracle, Teradata, Netezza → Redshift).
- **AWS Application Migration Service (MGN)** — **rehost / lift-and-shift** серверів (фізичних, VMware, Hyper-V, інших хмар) в EC2: безперервна блочна реплікація, короткий cutover.
- **AWS Elastic Disaster Recovery (DRS)** — DR серверів в AWS: постійна реплікація, RPO — секунди, RTO — хвилини.
- **VMware Cloud on AWS** — перенести VMware vSphere без змін (relocate).
- **7 R стратегій міграції:**
 - **Retire** — вимкнути непотрібне. **Retain** — поки залишити як є.
 - **Rehost** — lift & shift «як є» (MGN).
 - **Relocate** — перенести гіпервізор (VMware Cloud on AWS).
 - **Replatform** — lift, tinker & shift: невеликі оптимізації (БД → RDS, застосунок → Beanstalk).
 - **Repurchase** — перейти на SaaS.
 - **Refactor / Re-architect** — переписати під cloud-native (serverless, мікросервіси).

Тригери

On-prem застосунки зберігають файли в S3 через NFS/SMB з локальним кешем → **S3 File Gateway**

Замінити фізичні стрічки, залишивши наявне бекап-ПЗ → **Tape Gateway**

iSCSI-томи: основні дані в хмарі, локально лише кеш → **Volume Gateway (Cached)**

Усі дані мають бути локально з бекапом в AWS → **Volume Gateway (Stored)**

Перенести 50 TB з NAS в S3/EFS мережею — швидко, за розкладом, з перевіркою → **DataSync**

Партнери надсилають файли по SFTP, а зберігати треба в S3 → **Transfer Family**

Сотні терабайтів, повільний інтернет, дедлайн — тиждень → **Snowball Edge (нові клієнти — Data Transfer Terminal або партнери)**

Oracle → Aurora PostgreSQL з мінімальним простоем → **SCT (схема) + DMS (дані з CDC)**

MySQL on-prem → RDS MySQL з мінімальним простоем → **DMS (гомогенна, SCT не потрібен)**

Перенести сотні серверів «як є» в EC2 швидко → **Application Migration Service (MGN)**

DR для on-prem серверів в AWS з RPO в секунди → **Elastic Disaster Recovery**

Перенести віртуалки VMware без зміни інструментів → **VMware Cloud on AWS**

Невелика оптимізація при міграції: БД переносимо в керований сервіс → **Replatform (напр., на RDS)**

Пастки

DataSync — перенесення і синхронізація; Storage Gateway — постійний гібридний доступ; Transfer Family — протоколи SFTP/FTP.

SCT потрібен лише для гетерогенних міграцій (різні рушії БД).

Snowball — офлайн (фізично); DataSync — онлайн (мережею).

16 Бази даних: Amazon RDS

- Керовані реляційні БД: MySQL, PostgreSQL, MariaDB, Oracle, SQL Server, Db2. AWS робить патчі, бекапи, Multi-AZ. Доступу до ОС немає (виняток — **RDS Custom** для Oracle і SQL Server).
- **Multi-AZ (DB instance)** — **синхронна** standby-копія в іншій AZ, **автоматичний failover** (зазвичай 60–120 с, той самий DNS-endpoint). **Standby не обслуговує читання** — це для доступності, а не для масштабування.
- **Multi-AZ DB cluster** (MySQL, PostgreSQL) — 1 writer + **2 standby, з яких можна читати**, у 3 AZ; failover зазвичай до 35 с.
- **Read Replicas** — **асинхронні**, до 15 (MySQL, MariaDB, PostgreSQL), в інших AZ і **регіонах**. Для масштабування читання і звітів. Можна **promote** у самостійну БД (DR). Застосунок сам спрямовує читання на endpoint репліки. **Автоскейлінгу реплік у RDS немає** (в Aurora є).
- **Бекапи**: автоматичні (зберігання 1–35 днів, **point-in-time restore** з точністю до секунд, приблизно до останніх 5 хв) і ручні snapshots (живуть, доки не видалиш). Відновлення завжди створює **нову** БД з новим endpoint.
- **RDS Proxy** — пул з'єднань (Lambda, тисячі коротких з'єднань), швидший failover (до 66%), IAM-автентифікація, паролі з Secrets Manager. Код не змінюється — лише endpoint.
- **Storage autoscaling** — диск БД росте автоматично.
- **IAM database authentication** (MySQL, PostgreSQL) — токени замість паролів.
- **RDS Blue/Green Deployments** — безпечне оновлення версії БД з перемиканням менш ніж за хвилину.
- **Enhanced Monitoring** — метрики ОС бази (процеси, пам'ять) з інтервалом до 1 с. **Performance Insights** — які SQL-запити навантажують БД.
- **Зупинка RDS** — інстанс можна зупинити до 7 днів (потім він стартує сам). Економія для dev/test.

- Шифрування — лише при створенні (див. розділ 5).

Тригери

Висока доступність БД, автоматичний failover в іншу AZ → **RDS Multi-AZ**

Багато читань, звіти гальмують основну БД → **Read Replicas** (або кеш **ElastiCache**)

Недорогий DR БД в іншому регіоні → **Cross-Region Read Replica** (**promote при аварії**) або копіювання **snapshots**

Lambda вичерпує з'єднання до БД → **RDS Proxy**

Відновити БД на стан 10 хвилин тому → **Point-in-time restore** (створить нову БД)

Потрібен доступ до ОС бази (агенти, кастомні патчі) → **RDS Custom** (або БД на EC2)

Оновити версію БД з мінімальним простоем і можливістю відкату → **RDS Blue/Green Deployments**

Не зберігати паролі до БД у коді → **IAM DB authentication** або **Secrets Manager**

Потрібні і HA, і читання зі standby → **Multi-AZ DB cluster**

Потрібні метрики ОС бази (пам'ять процесів) щосекунди → **RDS Enhanced Monitoring**

Знайти SQL-запити, які найбільше навантажують БД → **Performance Insights**

Пастки

Multi-AZ = доступність (standby не читається). Read replica = масштабування читання (асинхронна, можлива затримка).

Restore зі snapshot або PITR створює **новий** інстанс з новим endpoint.

17 Amazon Aurora

- Сумісна з MySQL і PostgreSQL; за даними AWS — до 5× швидша за MySQL і до 3× за PostgreSQL.
- **6 копій даних у 3 AZ**, сховище росте автоматично до **256 TiB** (з 2025; раніше 128 TiB), самовідновлюється.
- **До 15 Aurora Replicas** на спільному сховищі (затримка реплікації зазвичай < 100 мс). **Автоматичний failover** на репліку (зазвичай до ~30 с), порядок — за failover tiers. **Aurora Auto Scaling** додає і прибирає репліки за навантаженням.

Endpoints

- **Writer (cluster) endpoint** — на поточний primary для запису (INSERT, UPDATE, DELETE). Після failover перемикається сам.
- **Reader endpoint** — балансує SELECT-запити між репліками.
- **Custom endpoints** — окремі групи реплік під різні навантаження (напр., аналітичні звіти окремо від веб-трафіку, більші інстанси — для звітів).
- **Instance endpoints** — до конкретного інстансу.

Катастрофостійкість і масштаб

- **Aurora Global Database** — реплікація **на рівні сховища до 10 вторинних регіонів** (з травня 2025; раніше 5). Затримка зазвичай < 1 с, RPO ~1 с, RTO < 1 хв. Локальне швидке читання в кожному регіоні; write forwarding.
- **Aurora Cross-Region Read Replica** (Aurora MySQL) — логічна реплікація (binlog) на рівні БД, більша затримка (від секунд до хвилин). Для мінімальних RPO/RTO — Global Database.

Спеціальні можливості

- **Aurora Serverless v2** — автоматично і миттєво масштабує потужність в **ACU** (1 ACU $\approx$ 2 GiB RAM + CPU і мережа). З кінця 2024 може опускатися до **0 ACU**: БД «засинає» (auto-pause), платиш лише за сховище, пробудження до ~ 15 с. Для непередбачуваних або переривчастих навантажень, dev/test. Можна змішувати з provisioned-інстансами в одному кластері.
- **Babelfish for Aurora PostgreSQL** — розуміє **T-SQL** і протокол SQL Server: застосунки з MS SQL Server переходять майже без змін коду.
- **Aurora Machine Learning** — ML-прогнози прямо в SQL-запитах (виклики **SageMaker AI**, **Comprehend**, **Bedrock**) без знань ML.
- **Aurora Backtrack** — «перемотати» кластер назад у часі (до 72 год) без відновлення з бекапу. **Тільки Aurora MySQL**.
- **Aurora Cloning** — швидка copy-on-write копія кластера (тести на свіжих даних без повної копії).
- **Aurora I/O-Optimized** — без плати за I/O; вигідно, коли I/O $>$ $\sim 25\%$ витрат на Aurora.
- **Zero-ETL integration з Redshift** — дані з Aurora майже в реальному часі доступні в Redshift без ETL-пайплайнів.
- **Aurora DSQL** (з 2025) — distributed serverless SQL (PostgreSQL-сумісна), active-active у кількох регіонах.

Тригери

Розділити аналітичне навантаження і веб-трафік на різні репліки →

Custom Endpoints

Найшвидша реплікація між регіонами, RPO ~ 1 с, RTO < 1 хв → **Aurora**

Global Database

Міграція з MS SQL Server без переписування T-SQL-коду → **Babelfish for Aurora PostgreSQL**

ML-прогнози через звичайні SQL-запити без знань ML → **Aurora Machine Learning (SageMaker AI / Comprehend)**

Непередбачувані сплески навантаження або БД «спить» уночі → [Aurora Serverless v2](#)

Випадково видалили дані — швидко повернути стан без відновлення з бекапу → [Aurora Backtrack \(тільки MySQL\)](#)

Швидко створити копію prod-бази для тестів → [Aurora Cloning](#)

Автоматично додавати репліки при зростанні читання → [Aurora Auto Scaling](#)

Аналітика в Redshift на даних з Aurora без ETL → [Zero-ETL integration](#)

Великі витрати на операції I/O в Aurora → [Aurora I/O-Optimized](#)

Максимальна доступність реляційної БД з мінімальним адмініструванням → [Amazon Aurora](#)

Читання всередині кожного регіону для глобального застосунку → [Aurora Global Database \(secondary regions\)](#)

Пастки

Backtrack є лише в Aurora MySQL. Для PostgreSQL — point-in-time restore або клон.

Global Database — реплікація сховища (швидка). Cross-Region Read Replica — логічна (повільніша).

Застосунок має писати через writer endpoint, а читати через reader/custom endpoints.

18 Amazon DynamoDB

- Serverless NoSQL (key-value і документи): **одноцифрові мілісекунди** на будь-якому масштабі, автоматично в кількох AZ. Елемент — до **400 KB**.
- Ключ: partition key (+ sort key). Індеси: **GSI** — інший partition key, можна додати будь-коли; **LSI** — той самий partition key з іншим sort key, лише під час створення таблиці.
- **Режими ємності:**
 - **On-demand** — плата за запити, без планування (непередбачуваний або новий трафік).
 - **Provisioned** — RCU/WCU + auto scaling (передбачуваний трафік, дешевше; можна reserved capacity).
- Читання: eventually consistent (за замовчуванням, дешевше) або **strongly consistent**. **Transactions** — ACID для кількох елементів.
- **DAX** — кеш у пам'яті перед DynamoDB: **мікросекунди**, сумісний API, код майже не змінюється. Тільки для DynamoDB.
- **Global Tables** — кілька регіонів, **multi-active** (запис у будь-якому регіоні). Eventual consistency або  (з 2025) **strong consistency між регіонами (RPO = 0)**.
- **DynamoDB Streams** — потік змін (зберігається 24 год) → Lambda: тригери, агрегації, реплікація. Kinesis Data Streams for DynamoDB — довше зберігання і більше споживачів.
- **TTL** — автоматичне безкоштовне видалення застарілих елементів (сесії, тимчасові дані).
- **Бекапи: PITR** до 35 днів з точністю до секунди, on-demand backups, AWS Backup. **Export to S3** без навантаження на таблицю → аналітика в Athena.
- Шифрування за замовчуванням. Доступ з VPC — через gateway endpoint.
- **Standard-IA table class** — дешевше зберігання для таблиць, які рідко читають.

Розрахунок ємності (RCU / WCU)

- **1 RCU** = 1 strongly consistent читання за секунду елемента до 4 KB, або 2 eventually consistent читання. Транзакційне читання — 2 RCU.
- **1 WCU** = 1 запис за секунду елемента до 1 KB. Транзакційний запис — 2 WCU.
- Розмір округлюється вгору: елемент 10 KB = 3 блоки по 4 KB (читання) і 10 блоків по 1 KB (запис).
- **Приклад:** 100 strongly consistent читань/с по 10 KB → $100 \times 3 = \mathbf{300 \text{ RCU}}$ (eventually consistent — **150 RCU**). 100 записів/с по 10 KB → **1 000 WCU**.
- **Partition key** обирай з високою кардинальністю (userId, orderId), щоб навантаження розподілялося. Інакше — «гаряча» партиція і throttling.

Тригери

Serverless БД з мілісекундною затримкою для мільйонів запитів, гнучка схема → **DynamoDB**

Мікросекундне читання з DynamoDB без переписування застосунку → **DAX**

Непередбачуваний трафік, платити лише за запити → **DynamoDB on-demand**

Стабільний передбачуваний трафік, дешевше → **Provisioned capacity + auto scaling**

Глобальний застосунок, запис і читання з низькою затримкою в кількох регіонах → **DynamoDB Global Tables**

Реагувати на кожну зміну в таблиці (надіслати email, оновити пошук) → **DynamoDB Streams + Lambda**

Автоматично видаляти сесії через 24 години → **TTL**

Відновити таблицю на будь-яку секунду за останні 35 днів → **Point-in-time recovery (PITR)**

SQL-аналітика на даних DynamoDB без навантаження на таблицю → **Export to S3 + Athena**

Кошки, сесії, лідерборди, IoT-дані, профілі гравців → **DynamoDB**

Потрібні складні JOIN і реляційна модель → **Не DynamoDB → RDS / Aurora**

Throttling, бо всі запити йдуть в один ключ (напр., поточна дата) → **Partition key з високою кардинальністю (userId) або write sharding**

Пастки

DAX — кеш лише для DynamoDB. Для RDS — ElastiCache.

LSI створюється тільки разом з таблицею. GSI можна додати будь-коли.

Елемент DynamoDB — максимум 400 KB. Великі файли → S3, а в таблиці — посилання.

Amazon ElastiCache

- Керований кеш у пам'яті: **Redis OSS / Valkey** і **Memcached**. Відповіді за мікросекунди–мілісекунди. Знімає навантаження з БД, зберігає сесії.
- **Redis / Valkey**: реплікація, Multi-AZ з автоматичним failover, persistence і бекапи, складні структури (**sorted sets** → **лідерборди**), pub/sub. Є serverless-варіант.
- **Memcached**: простий, багатопотоковий, шардування, **без реплікації і без persistence**.
- **Стратегії кешування**:
 - **Lazy loading (cache-aside)** — у кеш потрапляє те, що запитували; дані можуть застаріти → TTL.
 - **Write-through** — запис одночасно в БД і кеш; кеш завжди свіжий, але зберігає й непотрібне.
- Потребує **змін у коді** застосунку (логіка роботи з кешем).

Інші бази

- **Amazon Redshift** — сховище даних для аналітики (див. розділ 20).
- **Amazon DocumentDB** — документна БД, сумісна з **MongoDB**.
- **Amazon Neptune** — **графова** БД: соцмережі, рекомендації, виявлення шахрайських зв'язків, knowledge graphs.
- **Amazon Keyspaces** — сумісна з **Apache Cassandra** (CQL), serverless.
- **Amazon Timestream** — **часові ряди**: IoT, метрики, телеметрія.
- **Amazon MemoryDB** — Redis/Valkey-сумісна **основна** (не кеш) БД у пам'яті з durability.
- **Amazon QLDB** (ledger) — закритий 31.07.2025, не обирай.

Яку БД обрати

Вимога	Сервіс
Реляційна, SQL, JOIN, транзакції (OLTP)	RDS / Aurora

Вимога	Сервіс
Максимальна доступність і продуктивність реляційної БД	Aurora
Key-value, мілісекунди, будь-який масштаб, serverless	DynamoDB
Кеш, сесії, лідерборди	ElastiCache (Redis / Valkey)
Аналітика, OLAP, data warehouse, петабайти	Redshift
MongoDB-сумісна документна	DocumentDB
Графи, зв'язки	Neptune
Cassandra	Keyspaces
Часові ряди	Timestream
Повнотекстовий пошук, аналіз логів	OpenSearch

Тригери

Лідерборд гри в реальному часі → **ElastiCache for Redis/Valkey (sorted sets)**

Зберігати сесії користувачів для stateless-вебсерверів → **ElastiCache або DynamoDB**

Зменшити навантаження на RDS для повторюваних запитів → **ElastiCache (lazy loading)**

Простий багатопотоковий кеш без реплікації → **Memcached**

Перенести MongoDB-застосунок у керований сервіс → **DocumentDB**

Соцмережа «друзі друзів» або виявлення шахрайських зв'язків → **Neptune**

Перенести Cassandra в керований сервіс → **Keyspaces**

Показники IoT-датчиків з часовими мітками → **Timestream**

Кеш має пережити збій вузла без втрати даних → **ElastiCache Redis/Valkey з Multi-AZ і реплікацією**

Пастки

ElastiCache потребує змін у коді. Якщо сказано «без змін коду» — дивись на read replicas (RDS) або DAX (DynamoDB).

Memcached не має реплікації і не зберігає дані на диск.

Kinesis і Kafka

- **Kinesis Data Streams (KDS)** — потік у **реальному часі** (затримка ~70–200 мс), **власні споживачі** (Lambda, KCL-застосунки, Flink), кілька споживачів читають один потік, **replay**, порядок у межах shard.
 - Зберігання: 24 год за замовчуванням, до **365 днів**.
 - Shard: запис 1 MB/s або 1 000 записів/с, читання 2 MB/s (enhanced fan-out — 2 MB/s окремо кожному споживачу).
 - Режими: **on-demand** (масштабується сам) і provisioned (кількість shards).
 - Запис до 1 MiB ( з жовтня 2025 можна налаштувати до 10 MiB).
 - **Partition key** визначає shard. «Гарячий» shard → розділити його (split), обрати кращий ключ або перейти в on-demand.
- **Amazon Data Firehose** (колишній Kinesis Data Firehose) — **near real-time доставка** (з буферизацією) в **S3, Redshift, OpenSearch, Splunk, HTTP endpoints, Snowflake, Iceberg-таблиці**. Повністю керований, масштабується сам, **трансформація через Lambda, конвертація в Parquet/ORC**, стиснення. Replay і зберігання даних немає.
- **Managed Service for Apache Flink** (колишній Kinesis Data Analytics) — обробка потоків у реальному часі: агрегації у вікнах часу, виявлення аномалій (SQL, Java, Python).
- **Kinesis Video Streams** — потокове відео з камер для аналітики і ML (напр., Rekognition Video).
- **Amazon MSK** — керований **Apache Kafka** (для наявних Kafka-застосунків), MSK Serverless, MSK Connect.

ETL, запити, сховища даних

- **AWS Glue** — serverless **ETL** на Spark; **Data Catalog** (центральні метадані таблиць для Athena, Redshift Spectrum, EMR); **crawlers** (самі визначають схему); **job bookmarks** (обробляти лише нові дані); Glue DataBrew (візуальна підготовка даних без коду); конвертація **CSV → Parquet**.

- **Amazon Athena** — **serverless SQL** **прямо по файлах у S3**, плата за обсяг сканування (~\$5 за TB). Дешевше: формат **Parquet/ORC**, стиснення, **партиціювання**. Аналіз логів (CloudTrail, ALB, VPC Flow Logs, CloudFront). **Federated Query** — SQL до RDS, DynamoDB та інших джерел через конектори. **CTAS** (CREATE TABLE AS SELECT) перетворює CSV у Parquet прямо запитом.
- **Amazon EMR** — керований **Hadoop, Spark, Hive, Presto, HBase** для великих даних. Кластер на EC2 (primary / core / **task-вузли на Spot**), EMR Serverless, EMR on EKS. Коли потрібен контроль над фреймворками або вже є Spark/Hadoop-код.
- **Amazon Redshift** — колонкове **сховище даних** (OLAP, MPP): петабайти, складна аналітика SQL.
 - **Redshift Serverless** — без керування кластером.
 - **Redshift Spectrum** — запити до даних у S3 без завантаження.
 - **Concurrency Scaling** — додаткова потужність у пікові години.
 - **Zero-ETL** з Aurora, RDS і DynamoDB; data sharing.
 - DR — **cross-region snapshot copy**.
 - Найшвидше завантаження даних — команда **COPY** з S3 (паралельно з багатьох файлів).
- **Amazon OpenSearch Service** — повнотекстовий пошук і аналіз логів (аналог ELK), дашборди OpenSearch Dashboards, OpenSearch Serverless.
- **Amazon Quick** (колишній QuickSight) — BI-дашборди для бізнесу: serverless, SPICE (in-memory), ML insights, вбудовування в застосунки, row-level security.
- **AWS Lake Formation** — побудова і **безпека data lake** на S3: централізовані дозволи аж до **колонок, рядків і комірок** для Athena, Redshift Spectrum, EMR, Glue; шерінг між акаунтами.
- **AWS Data Exchange** — підписка на сторонні датасети (фінансові, погодні тощо) з доставкою в S3.

Схема: data lake і потоки даних



Джерела

Веб і мобільні застосунки, IoT, логи, БД (через DMS), SaaS (через AppFlow)



Приймання

Kinesis Data Streams реальний час

Data Firehose доставка в S3 (+ Parquet)



S3 raw

Сирі дані як є (CSV, JSON)



AWS Glue

Crawler + Data Catalog (схеми); ETL у Parquet з партиціями → S3 curated



Запити

Athena

Redshift Spectrum

EMR



Amazon Quick

Дашборди для бізнесу



Lake Formation — єдині дозволи до баз, таблиць, колонок і рядків для Athena, Redshift Spectrum, EMR і Glue

Реальний час з кількома споживачами і replay → Kinesis Data Streams. Просто скласти потік у S3 → Firehose. Разові SQL-запити по S3 → Athena; важка регулярна BI-аналітика → Redshift.

Тригери

Потік кліків або IoT у реальному часі, кілька застосунків-споживачів, replay → **Kinesis Data Streams**

Скласти потокові дані в S3, Redshift або OpenSearch без коду, near real-time → **Amazon Data Firehose**

Перетворити потік JSON у Parquet перед збереженням у S3 → **Firehose (конвертація формату)**

Аналіз потоку у вікнах часу, аномалії в реальному часі → **Managed Service for Apache Flink**

Наявні Kafka-застосунки → **Amazon MSK**

SQL-запити по логах або CSV у S3 без серверів → **Athena**

Знизити вартість запитів Athena → **Parquet + стиснення + партиціювання**

ETL без серверів, CSV → Parquet, каталог даних → **AWS Glue**

ETL при кожному запуску має обробляти лише нові файли → **Glue job bookmarks**

Великі задачі Spark/Hadoop, контроль над кластером, дешево → **EMR (task nodes на Spot)**

Складна BI-аналітика на петабайтах структурованих даних → **Redshift**

Запитувати дані в S3 з Redshift без завантаження → **Redshift Spectrum**

Повнотекстовий пошук по каталогу товарів, аналіз логів → **OpenSearch**

Інтерактивні дашборди для бізнесу → **Amazon Quick (QuickSight)**

Детальні права до колонок і рядків у data lake → **Lake Formation**

Отримувати сторонні датасети від постачальників → **AWS Data Exchange**

Відео з камер для аналізу ML → **Kinesis Video Streams**

Один shard Kinesis перевантажений (ProvisionedThroughputExceeded) → **Кращий partition key, split shard або on-demand режим**

Перетворити CSV у Parquet без окремого ETL-сервісу → **Athena CTAS (або Glue ETL)**

Швидко завантажити великі обсяги з S3 у Redshift → **Команда COPY**

Пастки

Kinesis Data Streams = реальний час + зберігання + replay. Firehose = доставка near real-time, без replay.

Athena — разові запити по S3; Redshift — постійне сховище для важкої регулярної аналітики.

21 Машинне навчання, AI і фронтенд

- **Amazon Rekognition** — аналіз зображень і відео: об'єкти, обличчя, модерація контенту, текст на фото.
- **Amazon Textract** — витягує текст, **форми і таблиці** зі сканів і PDF (більше, ніж звичайний OCR).
- **Amazon Comprehend** — NLP: тональність (sentiment), сутності, мова, ключові фрази, **PII** в тексті.
- **Amazon Transcribe** — мова → текст (субтитри, записи дзвінків), з приховуванням PII.
- **Amazon Polly** — текст → мова (озвучення).
- **Amazon Translate** — машинний переклад.
- **Amazon Lex** — чат-боти (голос і текст).
- **Amazon SageMaker AI** — побудова, навчання і розгортання **власних** ML-моделей.
- **AWS Amplify** — хостинг і бекенд для веб- і мобільних застосунків (full-stack), CI/CD фронтенду.
- **AWS Device Farm** — тестування застосунків на реальних телефонах, планшетах і браузерах.

Тригери

Розпізнати обличчя або об'єкти, модерація фото і відео → **Rekognition**

Витягнути дані з рахунків, форм і PDF → **Textract**

Визначити тональність відгуків або знайти PII в тексті → **Comprehend**

Перетворити записи дзвінків у текст → **Transcribe**

Озвучити текст → **Polly**

Перекласти контент на інші мови → **Translate**

Чат-бот для сайту або кол-центру → **Lex**

Навчити і розгорнути власну модель → **SageMaker AI**

Тестувати мобільний застосунок на сотнях реальних пристроїв → **Device Farm**

Швидко розгорнути фронтенд і бекенд веб/мобільного застосунку → **Amplify**

Конвеєр «аудіо → текст → переклад → озвучення» → **Transcribe** → **Translate** → **Polly**

Пастки

Готові AI-сервіси (Rekognition, Comprehend тощо) не потребують знань ML. SageMaker AI — для **власних** моделей.

- **CloudWatch Metrics:** EC2 за замовчуванням — CPU, мережа, диск (instance store), status checks; раз на 5 хв (detailed monitoring — раз на хвилину). **RAM і вільне місце на диску — ні!** → **CloudWatch agent**. Можна власні (custom) метрики.
- **CloudWatch Alarms** → SNS, ASG, дії EC2 (stop, terminate, reboot, **recover**), Systems Manager. **Composite alarms** — комбінація умов (менше хибних тривог).
- **CloudWatch Logs:** збір логів агентом і сервісами; retention налаштовується (за замовчуванням — назавжди); **metric filters** (напр., рахувати ERROR і ставити аларм); **Logs Insights** (запити); **subscription filters** → Lambda, Firehose, Kinesis, OpenSearch у реальному часі; експорт в S3.
- **CloudWatch Synthetics** (canaries — імітація користувача), Container Insights. **Amazon Managed Grafana** і **Managed Service for Prometheus** — дашборди і метрики контейнерів.
- **AWS CloudTrail** — журнал API-викликів: хто, що, коли, звідки.
 - Event history — **90 днів** management events безкоштовно.
 - **Trail** → S3 (довге зберігання) + CloudWatch Logs (аларми). **Organization trail** — усі акаунти.
 - **Data events** (об'єкти S3, виклики Lambda) — вимкнені за замовчуванням, платні.
 - **CloudTrail Insights** — незвична активність. **Log file integrity validation** — доказ, що логи не змінювали. **CloudTrail Lake** — SQL-запити по подіях.
- **AWS Config** — інвентар і **історія конфігурацій** ресурсів, **Config rules** (готові і власні) для compliance, **автоматичне виправлення** через SSM Automation, conformance packs, **aggregator** для багатьох акаунтів і регіонів.
- **AWS X-Ray** — трасування запитів через мікросервіси: де затримка або помилка, service map.

- **EventBridge + CloudTrail** — реагувати на конкретний API-виклик (напр., хтось змінив Security Group) → Lambda або SNS.
- **Anomaly detection alarms** у CloudWatch — аларм, коли метрика виходить за звичний коридор, без ручних порогів.
- **AWS Systems Manager (SSM):**
 - **Session Manager** — shell без SSH і бастіону.
 - **Run Command** — команди на всіх серверах одразу.
 - **Patch Manager + Maintenance Windows** — патчі ОС за розкладом.
 - **Parameter Store, Automation** (runbooks), State Manager, Inventory.
 - Працює і з on-prem серверами (hybrid activations).
- **AWS CloudFormation** — інфраструктура як код (шаблони YAML/JSON): однакові середовища, відтворення в іншому регіоні (DR). **StackSets** — розгортання в багатьох акаунтах і регіонах. **Change sets** — попередній перегляд змін. **Drift detection** — виявлення ручних змін. DeletionPolicy: Retain / Snapshot.
- **AWS Service Catalog** — каталог затверджених продуктів (шаблонів) для самообслуговування користувачів з обмеженими правами.
- **AWS Trusted Advisor** — рекомендації: вартість, продуктивність, безпека, стійкість, **ліміти сервісів**, операційна досконалість. Повний набір перевірок — з планами підтримки Business і вище.
- **AWS Compute Optimizer** — ML-рекомендації правильного розміру для EC2, ASG, EBS, Lambda, ECS на Fargate, RDS.
- **AWS Health Dashboard** — події AWS, що зачіпають твої ресурси (планове обслуговування, збої) → EventBridge.
- **AWS License Manager** — облік і контроль ліцензій (Microsoft, Oracle, SAP), заборона перевищення лімітів.
- **AWS Well-Architected Tool** — самоперевірка архітектури за 6 стовпами.

Тригери

Моніторити використання RAM і диска на EC2 → **CloudWatch agent**

Сповіщення, коли в логах «ERROR» з'являється частіше за N разів → **Metric filter + CloudWatch alarm → SNS**

Хто змінив або видалив ресурс і коли → **CloudTrail**

Журнал усіх API-викликів у всіх акаунтах організації → **Organization trail → S3**

Хто читає об'єкти в S3-bucket → **CloudTrail data events (або S3 server access logs)**

Автоматично перевіряти й виправляти невідповідні налаштування → **AWS Config rules + remediation (SSM Automation)**

Знайти, де виникає затримка між мікросервісами → **X-Ray**

Патчити сотні серверів за розкладом → **SSM Patch Manager + Maintenance Windows**

Виконати скрипт на всіх інстансах без SSH → **SSM Run Command**

Однаково розгорнути інфраструктуру в багатьох акаунтах і регіонах → **CloudFormation StackSets**

Користувачі мають самі запускати лише затверджені шаблони → **Service Catalog**

Інстанси завеликі, потрібні рекомендації щодо розміру → **Compute Optimizer**

Перевірити, чи наближаємося до лімітів сервісів → **Trusted Advisor / Service Quotas**

Сповіщення про планове обслуговування AWS, що зачепить наші інстанси → **AWS Health Dashboard + EventBridge**

Автоматично відновити EC2 при збої обладнання → **CloudWatch alarm (StatusCheckFailed_System) → recover**

Довести, що логи CloudTrail ніхто не змінював → **Log file integrity validation**

Дашборди метрик Prometheus для EKS без власного сервера →
Managed Service for Prometheus + Managed Grafana

Миттєве сповіщення, коли хтось змінює Security Group → **EventBridge rule на подію CloudTrail → SNS / Lambda**

Пастки

CloudTrail ≠ CloudWatch: Trail — аудит API-викликів; Watch — метрики, логи і аларми.

Метрики пам'яті за замовчуванням немає — тільки через агента.

- **RPO** (Recovery Point Objective) — скільки даних можна втратити (час від останньої копії до аварії).
- **RTO** (Recovery Time Objective) — за скільки часу система має знову запрацювати.

Стратегії DR (від найдешевшої до найдорожчої)

Стратегія	Що є в резервному регіоні	RPO / RTO	Вартість
Backup & Restore	Лише бекапи (snapshots, S3, AWS Backup)	Години	Найнижча
Pilot Light	Ядро: реплікована БД; сервери вимкнені або є лише AMI	Десятки хвилин	Низька
Warm Standby	Зменшена, але робоча копія всього стеку; при аварії масштабується	Хвилини	Середня
Multi-site Active-Active	Повна копія, постійно приймає трафік	Майже нуль	Найвища

Backup & Restore

У DR-регіоні лише бекапи

RPO/RTO: години



Pilot Light

Реплікована БД; сервери вимкнені
(готові AMI)

RPO/RTO: десятки хвилин



Warm Standby

Зменшена робоча копія всього стеку

RPO/RTO: хвилини



Active-Active

Повна копія, постійно обслуговує
трафік

RPO/RTO: майже нуль




дешевше, повільніше відновлення

дорожче, швидше відновлення

Обирай найдешевшу стратегію, яка вкладається в RPO і RTO з питання.

Шаблони



- **НА в одному регіоні:** ALB + ASG у ≥ 2 AZ + Multi-AZ БД + stateless-сервери (сесії в ElastiCache/DynamoDB) + статика в S3 + CloudFront.
- **Кілька регіонів:** Route 53 (failover/latency) або Global Accelerator; Aurora Global Database або DynamoDB Global Tables; S3 CRR; копії AMI і snapshots; CloudFormation для відтворення інфраструктури; квоти в DR-регіоні — заздалегідь.

- **AWS Backup** — централізовані плани бекапів для EC2, EBS, RDS, Aurora, DynamoDB, EFS, FSx, S3, Storage Gateway, DocumentDB, Neptune та ін.; **копії між регіонами й акаунтами**; **Backup Vault Lock** (WORM — ніхто не видалить бекапи, захист від ransomware); backup policies в Organizations; Backup Audit Manager.
- **Elastic Disaster Recovery** — постійна реплікація серверів, RPO секунди, RTO хвилини (див. розділ 15).
- **Immutable infrastructure** — не латати «живі» сервери, а замінювати новими з нового AMI (instance refresh, blue/green).
- **Legacy-застосунок без змін коду**: ASG (навіть $\min = \max = 1$ для автозаміни), ELB health checks, Multi-AZ RDS, RDS Proxy, EFS для спільних файлів, Route 53 health checks.
- **Стійкий код**: слабке зв'язування (SQS між шарами), повтори з exponential backoff і jitter, ідемпотентність обробки.

Тригери

RPO/RTO — години, мінімальна вартість → **Backup & Restore**

RTO — десятки хвилин; БД реплікується, сервери піднімаються під час аварії → **Pilot Light**

RTO — хвилини; зменшена копія працює постійно → **Warm Standby**

RPO і RTO майже нуль, трафік в обох регіонах → **Multi-site Active-Active**

Централізовані бекапи багатьох сервісів з копією в інший акаунт і регіон → **AWS Backup**

Бекапи не може видалити навіть адміністратор (ransomware) → **AWS Backup Vault Lock**

Застосунок на одному EC2 має автоматично відновлюватися після збою → **ASG з $\min = \max = 1$ (+ ELB health check)**

Швидко відтворити всю інфраструктуру в іншому регіоні → **CloudFormation (+ копії AMI)**

Реляційна БД з RPO ~1 с і RTO < 1 хв між регіонами → **Aurora Global Database**

NoSQL, запис у кількох регіонах одночасно → **DynamoDB Global Tables**

Копія об'єктів S3 в іншому регіоні з гарантованим часом → **S3 CRR + Replication Time Control**

Пастки

Multi-AZ захищає від збою AZ, але не від збою всього регіону — для цього потрібен інший регіон.

Read replica в іншому регіоні — це DR, але failover потребує promote (з можливою втратою останніх змін через асинхронність).

Обчислення

- Правильний розмір (Compute Optimizer), Spot для переривних задач, Savings Plans/RI для постійних, Graviton, serverless для переривчастих навантажень.
- Вимикати dev/test поза робочим часом (EventBridge Scheduler + Lambda або Instance Scheduler).
- ASG замість постійного запасу потужності.

Сховище

- Lifecycle у S3 (→ IA → Glacier), Intelligent-Tiering для невідомого патерну.
- gp3 замість gp2; видаляти старі snapshots і непідключені EBS-томи.
- EFS Infrequent Access / Archive; стиснення і формат Parquet для аналітики.

Бази даних

- Aurora Serverless v2 або DynamoDB on-demand — для нерівномірного навантаження; provisioned + резервування — для стабільного.
- Кеш (ElastiCache, DAX) замість дорожчого інстансу; read replicas замість вертикального масштабування.
-  **Database Savings Plans** — до 35% на RDS, Aurora, DynamoDB та ін.

Мережа (передача даних)

- Вхідний трафік в AWS — **безкоштовний**.
- Усередині однієї AZ по приватних IP — безкоштовно; **між AZ — платно**; між регіонами — платно; в інтернет — найдорожче.
- **Gateway endpoints** до S3/DynamoDB замість NAT Gateway (NAT бере плату за кожен ГБ).
- **CloudFront** зменшує витрати на вихідний трафік і навантаження на origin.

- NAT Gateway у кожній AZ — дорожче, але HA і без трафіку між AZ; одна NAT на всю VPC — дешевше, але єдина точка відмови (підходить для dev/test).
- Direct Connect — дешевший вихідний трафік для великих обсягів.
- Компоненти, що багато спілкуються, тримай в одній AZ або регіоні (якщо вимоги до HA дозволяють).
- **Transit Gateway vs VPC Peering:** TGW бере плату за кожне вклядення (attachment) і за кожен ГБ обробленого трафіку; peering — лише за трафік між AZ/регіонами. Для кількох VPC з великим трафіком peering дешевший.

Обчислення: що дешевше

- **Lambda vs EC2:** переривчасте або невелике навантаження — Lambda дешевша; постійне високе 24/7 — EC2 або Fargate із Savings Plans зазвичай дешевші.
- **RDS для dev/test** можна зупиняти до 7 днів (потім інстанс стартує сам) або перейти на Aurora Serverless v2.

Інструменти

- **AWS Cost Explorer** — аналіз і прогноз витрат, рекомендації RI і Savings Plans.
- **AWS Budgets** — сповіщення при перевищенні бюджету або прогнозу; **Budget Actions** — автоматичні дії (напр., обмежити запуск ресурсів).
- **AWS Cost and Usage Report (CUR)** / Data Exports — найдетальніші дані (кожен ресурс, кожна година) в S3 → Athena / Quick.
- **Cost Anomaly Detection** — ML-сповіщення про аномальні витрати.
- **Cost allocation tags** — розподіл витрат за проєктами і відділами (теги треба **активувати** в Billing).
- **Organizations consolidated billing** — один рахунок, об'ємні знижки, спільні RI/SP.
- **Pricing Calculator** — оцінка вартості майбутньої архітектури.

Тригери

Сповіщення, коли прогноз витрат перевищить \$1000 → [AWS Budgets](#)

Проаналізувати витрати за останні місяці і спрогнозувати наступні → [Cost Explorer](#)

Найдетальніші дані про витрати по кожному ресурсу для аналізу в Athena → [Cost and Usage Report](#)

Розподілити витрати між відділами або проєктами → [Cost allocation tags \(+ окремі акаунти\)](#)

Автоматично помітити раптовий стрибок витрат → [Cost Anomaly Detection](#)

Великий рахунок за NAT через трафік до S3 → [Gateway endpoint для S3](#)

Великі витрати на вихідний трафік для статичного контенту → [CloudFront](#)

Dev/test-сервери потрібні лише в робочі години → [Зупиняти за розкладом \(EventBridge Scheduler + Lambda\)](#)

Постійні інстанси 24/7 → [Savings Plans / Reserved Instances](#)

Невідомий патерн доступу до об'єктів S3 → [S3 Intelligent-Tiering](#)

Зменшити трафік між AZ для dev-середовища → [Одна NAT Gateway / ресурси в одній AZ](#)

Дві VPC обмінюються великим обсягом даних, потрібне найдешевше з'єднання → [VPC Peering \(не Transit Gateway\)](#)

Постійне високе навантаження 24/7 на Lambda, рахунки ростуть → [EC2 або Fargate + Savings Plans](#)

Знайти дані, які варто перевести в дешевші класи S3 → [S3 Storage Class Analysis / Storage Lens](#)

Пастки

«Найдешевше» на іспиті = найдешевше з тих, що **виконують усі вимоги**. Дешевий варіант без НА програє, якщо в питанні потрібна НА.

Трафік між AZ платний — навіть усередині однієї VPC.

25 Цифри, ліміти і порти

Усі цифри звірені з документацією AWS станом на вересень 2026. На іспиті частіше питають не саму цифру, а наслідок: «Lambda — 15 хв, отже задача на годину — не Lambda».

Іспит

Що	Значення
Питання / час	65 (50 оцінюваних) / 130 хв (+30 хв з ESL +30)
Прохідний бал	720 з 1000
Ціна / строк дії	\$150 / 3 роки

Обчислення

Що	Ліміт
Lambda — тривалість	15 хв
Lambda — пам'ять	128 MB – 10 240 MB (CPU росте разом з пам'яттю)
Lambda — /tmp	512 MB – 10 GB
Lambda — payload	6 MB синхронно, 1 MB асинхронно
Lambda — код	50 MB zip, 250 MB розпакований, container image — 10 GB
Lambda — concurrency	1 000 на регіон за замовчуванням
Spot — попередження	2 хвилини
Spread placement group	7 інстансів на AZ
Partition placement group	до 7 partitions на AZ
ASG — cooldown	300 с за замовчуванням
Знижки	Spot до 90%; RI і EC2 Instance SP до ~72%; Compute SP до ~66%; Database SP до 35%

Сховище

Що	Ліміт
S3 — об'єкт	до 50 TB (раніше 5 TB); один PUT — до 5 GB
S3 — multipart	рекомендовано від 100 MB, обов'язково понад 5 GB
S3 — продуктивність	3 500 запитів на запис і 5 500 на читання за секунду на префікс
S3 — мінімальний строк	IA — 30 днів; Glacier Instant і Flexible — 90; Deep Archive — 180
S3 — мінімальний розмір оплати	128 KB (Standard-IA, One Zone-IA, Glacier Instant)
Glacier Flexible — отримання	Expedited 1–5 хв, Standard 3–5 год, Bulk 5–12 год
Glacier Deep Archive — отримання	Standard до 12 год, Bulk до 48 год
S3 Replication Time Control	99,99% об'єктів за 15 хв
EBS gp3	базово 3 000 IOPS і 125 MiB/s; до 80 000 IOPS, 2 000 MiB/s, 64 TiB
EBS io2 Block Express	до 256 000 IOPS, 4 000 MiB/s, 64 TiB
EBS gp2	3 IOPS на GiB, максимум 16 000
EBS st1 / sc1	500 / 250 MiB/s; не можуть бути boot-томом
EBS Multi-Attach	io1/io2, до 16 Nitro-інстансів в одній AZ

Бази даних

Що	Ліміт
RDS — автоматичні бекапи	1–35 днів
RDS — read replicas	до 15 (MySQL, MariaDB, PostgreSQL)
RDS Multi-AZ — failover	зазвичай 60–120 с (Multi-AZ DB cluster — до ~35 с)
RDS — зупинка	до 7 днів, потім стартує сам
Aurora	6 копій у 3 AZ, до 15 реплік, до 256 TiB

Що	Ліміт
Aurora Global Database	до 10 вторинних регіонів, затримка < 1 с, RTO < 1 хв
Aurora Backtrack	до 72 год, лише MySQL
Aurora Serverless v2	1 ACU ≈ 2 GiB RAM, мінімум 0 ACU
DynamoDB — елемент	400 KB
DynamoDB — PITR / Streams	35 днів / 24 год
DynamoDB — RCU / WCU	1 RCU = 1 strongly consistent читання/с до 4 KB (або 2 eventual); 1 WCU = 1 запис/с до 1 KB

Інтеграція і потоки

Що	Ліміт
SQS — повідомлення	до 1 MiB (Extended Client Library — до 2 GB через S3)
SQS — зберігання	1 хв – 14 днів (за замовчуванням 4 дні)
SQS — visibility timeout	30 с за замовчуванням, максимум 12 год
SQS — long polling / delay	до 20 с / до 15 хв
SQS FIFO	300 викликів/с (3 000 повідомлень/с з батчами по 10); дедуплікація 5 хв
SNS — повідомлення	256 KB (до 1 MiB за налаштуванням з вересня 2026)
Kinesis Data Streams	зберігання 24 год – 365 днів; shard: запис 1 MB/s або 1 000 записів/с, читання 2 MB/s
Step Functions	Standard — до 1 року; Express — до 5 хв
API Gateway	таймаут інтеграції 29 с; payload 10 MB; 10 000 запитів/с (burst 5 000)

Мережа

Що	Ліміт
VPC — CIDR	від /16 до /28; 5 зарезервованих IP у кожній підмережі
NACL — ephemeral ports	1024–65535

Що	Ліміт
Site-to-Site VPN	2 тунелі; до 1,25 Gbps на тунель (large — до 5 Gbps)
Direct Connect	Dedicated 1/10/100/400 Gbps; Hosted 50 Mbps – 25 Gbps
Global Accelerator	2 статичні anycast IP
Route 53 multivalued	до 8 записів у відповіді
ELB deregistration delay	300 с за замовчуванням
Gateway Load Balancer	протокол GENEVE, порт 6081

Безпека і моніторинг

Що	Ліміт
KMS — пряме шифрування	до 4 KB (більше — envelope encryption)
KMS — ротація	раз на рік за замовчуванням (90–2560 днів або вручну)
KMS — видалення ключа	очікування 7–30 днів
CloudTrail — Event history	90 днів
CloudWatch — метрики EC2	5 хв (detailed monitoring — 1 хв)
CloudWatch Logs	зберігаються безстроково, доки не задаш retention
Shield Advanced	~\$3 000 на місяць на організацію

Порти, які варто знати

Порт	Протокол або сервіс
22	SSH
3389	RDP (Windows)
80 / 443	HTTP / HTTPS
3306	MySQL, MariaDB, Aurora MySQL
5432	PostgreSQL, Aurora PostgreSQL
1433	Microsoft SQL Server
1521	Oracle
2049	NFS (EFS)

Порт	Протокол або сервіс
445	SMB (FSx for Windows)
6379	Redis OSS / Valkey
11211	Memcached
53	DNS

Мережа

- **Security Group vs NACL:** SG — інстанс, stateful, лише Allow, посилання на інші SG. NACL — підмережа, stateless, Allow + Deny, правила за номерами.
- **Gateway vs Interface endpoint:** Gateway — лише S3 і DynamoDB, безкоштовно, запис у route table. Interface — майже всі сервіси, ENI з приватним IP, платно, доступний з on-prem.
- **VPC Peering vs Transit Gateway vs PrivateLink:** Peering — 1:1, нетранзитивно, дешево. TGW — хаб на сотні VPC і on-prem, транзитивно. PrivateLink — доступ до одного конкретного сервісу, односторонній, CIDR можуть перетинатися.
- **Site-to-Site VPN vs Direct Connect:** VPN — через інтернет, шифрування IPsec, налаштування за хвилини, дешево. DX — приватний канал, стабільна швидкість, прокладання тижнями, шифрування окремо (VPN поверх DX або MACsec).
- **CloudFront vs Global Accelerator:** CloudFront — кеш HTTP-контенту на edge. Global Accelerator — без кешу, TCP/UDP, 2 статичні IP, швидкий failover між регіонами.
- **ALB vs NLB vs GWLB:** ALB — рівень 7, роутинг HTTP за шляхом і хостом, Lambda як ціль. NLB — рівень 4, TCP/UDP, статичні IP, мільйони запитів/с. GWLB — рівень 3, прогін трафіку через апарати безпеки.
- **Route 53 Geolocation vs Geoproximity vs Latency:** Geolocation — за країною користувача. Geoproximity — за відстанню з можливістю змістити трафік (bias). Latency — до регіону з найменшою затримкою.

Обчислення

- **Lambda vs Fargate vs EC2 vs Batch:** Lambda — події задачі до 15 хв. Fargate — контейнери без серверів, без ліміту часу. EC2 — повний контроль, особливі вимоги (GPU, ліцензії, ОС). Batch — черги пакетних задач будь-якої тривалості.

- **ECS vs EKS:** ECS — простіше, «рідне» для AWS. EKS — Kubernetes (вже є K8s, портативність).
- **Spot vs Reserved vs Savings Plans vs On-Demand:** Spot — до 90%, може перерватися. RI/SP — 1–3 роки, до ~72%, для постійного навантаження. On-Demand — без зобов'язань, найдорожче.
- **Dedicated Host vs Dedicated Instance:** Host — видно фізичний сервер, сокети і ядра (BYOL). Instance — лише ізоляція обладнання.
- **Scheduled vs Predictive vs Target tracking:** Scheduled — відомий час піку. Predictive — ML за історією циклів. Target tracking — тримати метрику на рівні.
- **Elastic Beanstalk vs CloudFormation:** Beanstalk — PaaS для розгортання застосунку. CloudFormation — IaC для будь-якої інфраструктури.

Сховище

- **S3 vs EBS vs EFS vs FSx vs Instance store:** S3 — об'єкти, необмежено, доступ по HTTP. EBS — блочний диск, одна AZ. EFS — спільні файли NFS для Linux у кількох AZ. FSx — Windows (SMB) / Lustre (HPC) / ONTAP (NFS + SMB + iSCSI) / OpenZFS. Instance store — ефемерний локальний диск.
- **DataSync vs Storage Gateway vs Transfer Family vs Snowball:** DataSync — перенесення мережею. Storage Gateway — постійний гібридний доступ з кешем. Transfer Family — SFTP/FTP для партнерів. Snowball — фізичне офлайн-перенесення.
- **Volume Gateway Cached vs Stored:** Cached — основні дані в S3, кеш локально. Stored — усе локально, бекап в S3.
- **Object Lock Compliance vs Governance:** Compliance — не обійде ніхто, навіть root. Governance — можуть обійти користувачі з окремим дозволом.
- **CloudFront signed URL vs signed cookies vs S3 presigned URL:** signed URL — один файл через CloudFront. Signed cookies — багато файлів через CloudFront. Presigned URL — напряду до одного об'єкта S3.
- **OAC vs OAI:** OAC — сучасний спосіб закрити S3 за CloudFront (підтримує SSE-KMS). OAI — застарілий.

Бази даних

- **RDS Multi-AZ vs Read Replica:** Multi-AZ — синхронна копія, HA, standby не читається. Read replica — асинхронна, масштабування читання, можна в іншому регіоні.
- **Aurora Global Database vs Cross-Region Read Replica:** Global DB — реплікація сховища < 1 с, RTO < 1 хв. Cross-region replica — логічна, від секунд до хвилин.
- **DAX vs ElastiCache:** DAX — лише для DynamoDB, код майже не змінюється. ElastiCache — для будь-якої БД, логіку кешу пише застосунок.
- **Redis/Valkey vs Memcached:** Redis — реплікація, Multi-AZ, persistence, складні структури. Memcached — простий багатопотоковий кеш без реплікації.
- **Athena vs Redshift vs EMR:** Athena — serverless SQL по S3 для разових запитів. Redshift — сховище даних для важкої регулярної BI-аналітики. EMR — кластери Spark/Hadoop.
- **Enhanced Monitoring vs Performance Insights (RDS):** Enhanced Monitoring — метрики ОС (до 1 с). Performance Insights — які SQL-запити навантажують БД.
- **Kinesis Data Streams vs MSK:** KDS — «рідний» сервіс AWS з shards. MSK — керований Apache Kafka для наявних Kafka-застосунків.

Інтеграція і потоки

- **SQS vs SNS vs EventBridge vs Kinesis:** SQS — черга, споживачі забирають (pull). SNS — pub/sub, розсилка (push). EventBridge — маршрутизація подій за правилами, SaaS, розклад. Kinesis — потоки даних у реальному часі з replay.
- **Kinesis Data Streams vs Firehose:** KDS — реальний час, свої споживачі, replay. Firehose — near real-time доставка в сховища без коду.
- **SQS Standard vs FIFO:** Standard — максимальна швидкість, можливі дублікати і зміна порядку. FIFO — суворий порядок і обробка рівно один раз.

- **Step Functions Standard vs Express:** Standard — до 1 року, exactly-once, історія. Express — до 5 хв, великі обсяги, дешевше.

Безпека

- **Secrets Manager vs Parameter Store:** Secrets Manager — автоматична ротація, реплікація між регіонами, платно. Parameter Store — без вбудованої ротації, standard tier безкоштовний.
- **KMS vs CloudHSM:** KMS — керований сервіс, інтеграція з усіма сервісами AWS. CloudHSM — виділений апаратний модуль, повний контроль над ключами, FIPS 140 Level 3.
- **Cognito User Pool vs Identity Pool:** User Pool — вхід користувачів (JWT). Identity Pool — тимчасові AWS-credentials.
- **IAM Identity Center vs Cognito:** Identity Center — співробітники в акаунтах AWS і бізнес-застосунках. Cognito — клієнти твого застосунку.
- **Managed Microsoft AD vs AD Connector vs Simple AD:** Managed AD — справжній AD в AWS з trust. AD Connector — проксі до on-prem AD. Simple AD — дешевий базовий, без trust.
- **CloudTrail vs Config vs CloudWatch:** CloudTrail — хто і коли викликав API. Config — яка була конфігурація і чи відповідає вона правилам. CloudWatch — метрики, логи, аларми.
- **GuardDuty vs Inspector vs Macie vs Detective vs Security Hub:** загрози / вразливості / чутливі дані в S3 / розслідування / єдина панель.
- **WAF vs Shield vs Network Firewall vs Firewall Manager:** WAF — рівень 7 (HTTP). Shield — DDoS. Network Firewall — файрвол рівня VPC. Firewall Manager — централізоване керування всім цим в Organizations.
- **SCP vs Permission boundary vs IAM policy:** SCP — стеля для цілих акаунтів/OU. Permission boundary — стеля для конкретного користувача або ролі. IAM policy — власне надає дозволи.

27 Пастки, на яких найчастіше ловлять

⚠ Найчастіші пастки

У Security Group **немає Deny**. Заблокувати IP → NACL або WAF.

Standby в RDS Multi-AZ (DB instance) **не обслуговує читання**.

Read replicas **асинхронні** — остання частина даних може бути ще не скопійована.

Gateway endpoint — лише **S3 і DynamoDB** і не працює з on-prem.

WAF не ставиться на NLB.

SCP не надає дозволів і не діє на management account.

Lambda — максимум **15 хвилин**.

EBS прив'язаний до AZ; instance store втрачає дані при зупинці.

EFS — тільки Linux (NFS); для Windows — FSx for Windows File Server.

Шифрування існуючих RDS/EBS — лише через копію снапшота.

Сертифікат ACM для CloudFront — тільки в **us-east-1**.

CloudWatch не бачить **RAM** і місце на диску без агента.

IA- і Glacier-класи мають **мінімальний термін оплати** (30 / 90 / 180 днів) і мінімальний розмір об'єкта 128 KB (IA, Glacier Instant Retrieval).

Aurora Backtrack — лише MySQL.

SQS Standard може доставити повідомлення **двічі і не за порядком**.

VPC Peering нетранзитивний і не працює з перетином CIDR.

Route 53 health checks не бачать приватні ресурси напряму — потрібен CloudWatch alarm.

Direct Connect **не шифрує** трафік сам по собі.

Spot може бути перерваний з попередженням лише за 2 хвилини.

Сервіси «One Zone» (S3 One Zone-IA, Express One Zone, EFS One Zone) не переживуть втрату AZ.

«Свій скрипт на EC2 / cron» майже завжди програє керованому сервісу.

Presigned URL працює з правами того, хто його підписав, і не довше, ніж діють його облікові дані.

Класичний NAT Gateway стоїть у **public** subnet, а маршрут `0.0.0.0/0` на нього прописують у route table **private** subnet.

Cross-zone load balancing у NLB вимкнений за замовчуванням.

RDS не вміє автоматично додавати read replicas (Aurora вміє).

LSI у DynamoDB створюється лише разом з таблицею.

Трафік між AZ платний, навіть в одній VPC.

Снапшот, зашифрований **AWS managed key**, не можна віддати іншому акаунту — лише з customer managed key.

Route 53 alias на S3 website працює, лише якщо ім'я bucket збігається з доменом.

Lambda + SQS: visibility timeout черги має бути щонайменше в 6 разів більшим за timeout функції.

Restore RDS зі снапшота або PITR дає **новий** endpoint — застосунок треба переналаштувати.

28 Що змінилося у 2024–2026 (нові цифри і назви)

На іспиті можуть траплятися **старі** цифри й назви — відповідай за логікою питання. Але знай актуальні:

- **S3:** об'єкт до **50 TB** (грудень 2025; раніше 5 TB).
- **SQS:** повідомлення до **1 MiB** (серпень 2025; раніше 256 KB).
- **SNS:** повідомлення до **1 MiB** за налаштуванням (вересень 2026; раніше 256 KB).
- **Lambda:** асинхронний payload **1 MB** (раніше 256 KB).
- **EBS gp3:** до **64 TiB, 80 000 IOPS, 2 000 MiB/s** (вересень 2025; раніше 16 TiB / 16 000 / 1 000).
- **Aurora:** сховище до **256 TiB** (2025); Global Database — до **10** вторинних регіонів (травень 2025; раніше 5); Serverless v2 опускається до **0 ACU** (листопад 2024).
- **DynamoDB Global Tables:** strong consistency між регіонами (червень 2025).
- **Kinesis Data Streams:** записи до **10 MiB** (жовтень 2025; раніше 1 MiB).
- **Site-to-Site VPN:** тунелі до **5 Gbps** (листопад 2025; раніше 1,25 Gbps).
- **Regional NAT Gateway** — один NAT на всю VPC (листопад 2025).
- **Database Savings Plans** — до 35% на бази даних (грудень 2025).
- **Закриті для нових клієнтів:** Snowball Edge, старий сервіс Amazon Glacier (vaults), S3 Object Lambda, Migration Hub, Application Discovery Service (з листопада 2025), FSx File Gateway (з жовтня 2024), S3 Select (з липня 2024). Elastic Transcoder закрито 13.11.2025 (заміна — Elemental MediaConvert). QLDB — кінець підтримки 31.07.2025.
- **Перейменування:** QuickSight → **Amazon Quick**; SageMaker → **SageMaker AI**; Kinesis Data Firehose → **Amazon Data Firehose**; Kinesis Data Analytics → **Managed Service for Apache Flink**.

Як вчитися на цьому сайті

-  **Шпаргалка** — прочитай розділ, потім увімкни « Сховати відповіді» і пройди тригери, торкаючись розмитої відповіді лише після того, як сам відповів. Позначай «Вивчено».
-  **Швидко** — лише тригери, пастки, порівняння і цифри. Для повторення в останні дні.
-  **Схеми** — усі архітектурні схеми в одному місці.
-  **Квіз** — випадкові тригери; ті, що «не знав», повертаються частіше.
-  **Тест** — 65 практичних питань у стилі іспиту: режим «Тренування» (пояснення одразу) і «Іспит» (таймер, результат у кінці).
- Прогрес зберігається в браузері телефона. Сайт працює і без інтернету, якщо хоч раз відкрити його онлайн. На телефоні його можна додати на головний екран як застосунок.

План на 14 днів (1–2 години на день)

День	Що вчити	Практика
1	Розділи 1–3: іспит, тактика, основи	Квіз: 20 тригерів
2	4–5: IAM, шифрування	Квіз по розділах 4–5
3	6: сервіси безпеки	Тест: набір «Безпека» у режимі «Тренування»
4	7: VPC і мережа, схеми VPC і гібриду	Квіз по розділу 7
5	8–9: Route 53, CloudFront, Global Accelerator, ELB, Auto Scaling	Квіз по розділах 8–9
6	10–11: EC2, serverless, контейнери	Квіз по розділах 10–11
7	12: SQS, SNS, EventBridge, Step Functions	«  Швидко» по днях 1–6
8	13–14: S3, EBS, EFS, FSx	Тест: набір «Продуктивність»
9	15–17: міграція, RDS, Aurora	Квіз по розділах 15–17
10	18–19: DynamoDB, кеш, інші БД	Тест: набір «Відмовостійкість»

День	Що вчити	Практика
11	20–22: аналітика, ML, моніторинг	Квіз по розділах 20–22
12	23–25: DR, вартість, цифри	Тест: набір «Вартість»
13	Повний тест у режимі «Іспит» (130 хв)	Розібрати кожну помилку
14	26–28: порівняння, пастки, зміни	«Мої помилки» в тесті + « ⚡ Швидко»

- Якщо стабільно набираєш **80%+** у практичних тестах — записуйся на іспит.
- Додатково: офіційний безкоштовний набір питань AWS (Official Practice Question Set) у **AWS Skill Builder**; популярні платні тести — Tutorials Dojo.
- Подай запит **ESL +30 хвилин до запису** на іспит.

День іспиту: чек-лист

- **Документ:** паспорт або інше посвідчення з фото; ім'я має збігатися з ім'ям у профілі AWS Certification.
- **Онлайн-іспит (Pearson VUE, OnVUE):** заздалегідь пройди перевірку системи (system test) на тому самому комп'ютері й мережі. Check-in відкривається за 30 хв до початку. Потрібні тиха окрема кімната, чистий стіл, телефон поза досяжністю; кімнату фотографуєш під час check-in.
- Під час онлайн-іспиту перерв, як правило, немає — підготуйся заздалегідь. Говорити вголос і виходити з кадру не можна. Нотатки — лише на вбудованій цифровій дошці (whiteboard).
- **У центрі тестування** приходь раніше; речі залишаєш у шафці, для нотаток дають дошку.
- **Тактика:** ~2 хв на питання. Не знаєш — познач (flag), дай найкращу відповідь, повернися в кінці. Відповідай на **всі** питання, бо штрафу немає.
- Спершу читай останнє речення питання, шукай ключові слова: **MOST cost-effective, LEAST operational overhead, highly available, real-time.**

- Результат прийде на email і в кабінет, зазвичай за кілька годин (до 5 робочих днів).

Джерела

- Офіційний гайд іспиту SAA-C03 (AWS) — домени, завдання, сервіси в межах іспиту
- Сторінка сертифікації AWS SAA — формат, ціна, мови
- Правила перед іспитом, accommodations (AWS)
- AWS Well-Architected Framework
- Логіка оцінки політик IAM
- Класи зберігання S3 і варіанти відновлення з Glacier
- Типи томів EBS
- Ліміти Lambda і ліміти SQS
- Read replicas у RDS
- Оголошення AWS: S3 50 TB, SQS 1 MiB, SNS 1 MiB, gp3, Aurora Global Database 10 регіонів, Aurora Serverless v2 до 0 ACU, Kinesis 10 MiB, VPN 5 Gbps, Regional NAT Gateway, DynamoDB strong consistency між регіонами, Database Savings Plans, зміни доступності сервісів
- Шпаргалки спільноти, з якими звірявся: awsfundamentals.com, [GitHub sv222](https://github.com/sv222)
- Практичні питання в розділі «Тест» — оригінальні, складені для навчання; це не реальні питання іспиту